

面向配电网拓扑辨识的贝叶斯树结构建模与边置 信度估计理论笔记

科研写作辅助稿

2026 年 7 月 9 日

目录

导读	4
第一章 问题背景与基本目标	5
1.1 配电网拓扑辨识的典型设定	5
1.2 基本符号	5
1.3 总体目标	6
第二章 贝叶斯理论基础	7
2.1 条件概率	7
2.2 贝叶斯公式	7
2.3 先验、似然、后验的直观含义	8
2.4 MAP 与 MLE	8
第三章 从参数后验到拓扑后验	9
3.1 拓扑是离散结构变量	9
3.2 对线路参数的边缘化	9
第四章 AC 潮流残差如何形成似然	10
4.1 高斯测量噪声下的残差似然	10
4.2 温度参数与模型错设补偿	10
4.3 输入变量也有误差时的 EIV 形式	11
第五章 拓扑先验的常见形式	12
5.1 先验的角色	12
5.2 均匀树先验	12
5.3 距离矩阵先验	12
5.4 阻抗、地理和工程规则先验	13
第六章 边后验概率	14
6.1 定义	14
6.2 边后验与边权的区别	14

目录	2
第七章 Matrix-Tree Theorem 与可分解树后验	15
7.1 边可加分数	15
7.2 矩阵树定理	15
7.3 边边缘概率	16
7.4 局限性	16
第八章 Chow-Liu Tree 与 Soft Chow-Liu	17
8.1 树结构概率分布	17
8.2 Chow-Liu 的目标	17
8.3 Soft Chow-Liu	18
8.4 在配电网中的解释边界	18
第九章 AC 残差不可分解时的近似边概率估计	19
9.1 为什么不能直接用 Matrix-Tree	19
9.2 局部替代树 softmax	19
9.3 候选树集合归一化	20
9.4 MCMC over Trees	20
第十章 Bootstrap 稳定性不是贝叶斯后验，但很有用	21
10.1 Block bootstrap 的思想	21
10.2 解释边界	21
第十一章 Score Gap 与 Replacement Edge 敏感性	22
11.1 最大生成树中的边敏感度	22
11.2 AC 残差 gap	22
第十二章 仿真校准：把置信指标转成经验正确率	23
12.1 从指标到经验正确率	23
12.2 与贝叶斯后验的区别	23
第十三章 综合算法框架	24
13.1 算法解释	26
第十四章 常见误区与解释边界	27
14.1 后验概率不是客观真理	27
14.2 距离权重不是边概率	27
14.3 Matrix-Tree 的适用范围	27
14.4 Chow-Liu 不是物理拓扑辨识的全部	27
14.5 Bootstrap 稳定性不是贝叶斯后验	27

目录	3
14.6 Reduced topology 与真实物理线路	28
14.7 低置信边不等于算法错误	28
第十五章 符号表	29
第十六章 总结	30

导读

本文试图把几个常被混在一起的概念拆开：贝叶斯后验概率、基于模型残差构造的置信度、bootstrap 稳定性，以及由仿真校准得到的经验正确率。它们都可以服务于配电网拓扑辨识，但数学含义并不相同。若不加区分，容易把“某条边的分数高”“某条边在重采样中频繁出现”和“某条边在真实拓扑中出现的后验概率高”误认为同一件事。

本文关注的场景是：候选配电网近似为径向树，根节点和末端智能电表可观测，中间可能存在零注入或低注入的 hidden nodes；距离矩阵、相关性矩阵或互信息矩阵只能给出粗略线索；最终仍希望用 AC 潮流残差判断候选拓扑是否能解释观测到的电压、功率和根节点电压。这个场景比标准的最小生成树或 Chow-Liu tree 更困难，因为 AC 残差通常不是边可加的全局目标。

第一章 问题背景与基本目标

1.1 配电网拓扑辨识的典型设定

配电网在正常运行中常被调度为径向结构。也就是说，除根节点或变电站外，每个节点通常只有一条通向上游的路径。这一事实使得“树”成为拓扑辨识的自然数学对象。然而真实量测条件往往并不理想：根节点可观测，末端用户侧智能电表可能记录有功功率、无功功率和电压幅值，中间杆塔、接线箱或分支节点却未必有传感器；这些中间节点还可能近似零注入，使其在量测层面更像隐藏变量。

在这样的系统中，若只根据估计出的距离矩阵或相关性矩阵做最小生成树，得到的树未必能解释 AC 潮流关系。距离矩阵可能受负荷相关性、噪声、公共上游扰动、采样窗口和参数错设影响。本文的核心目标不是把距离最短的边都连起来，而是构造一种概率化框架：工程先验给出候选树的初始偏好，AC 潮流残差给出数据对候选拓扑的支持程度，最后用边后验概率或近似置信度表达每条边的可信程度。

1.2 基本符号

记观测数据为

$$D = \{P_t^m, Q_t^m, V_t^m, V_{0,t}^m\}_{t=1}^N, \quad (1.1)$$

其中 P_t^m, Q_t^m 表示第 t 个时刻末端量测节点的有功、无功注入向量， V_t^m 表示末端电压量测向量， $V_{0,t}^m$ 表示根节点电压量测。上标 m 强调这些量是 measurement，而不一定等于真实物理值。

令 $G = (\mathcal{V}, \mathcal{E}_c)$ 为候选图， $\mathcal{E}_c$ 是允许出现的候选边集合。所有候选生成树组成集合

$$T \in \mathcal{T}(G). \quad (1.2)$$

对一棵给定拓扑 T ，令

$$\theta_T = \text{线路参数或待估计物理参数}, \quad (1.3)$$

例如支路电阻、电抗、等值负荷修正量，或者隐藏节点消元后的等效参数。

给定拓扑和参数后，AC 潮流模型把功率和根节点电压映射为末端电压预测：

$$h_T(P_t, Q_t, V_{0,t}; \theta_T) = \text{在拓扑 } T \text{ 下的 AC 潮流预测电压}. \quad (1.4)$$

如果模型、参数和拓扑都正确，则 h_T 应当接近观测电压 V_t^m 。若残差系统性偏大，则该拓扑可能与真实网络不一致，或者线路参数、注入量、噪声模型存在错设。

1.3 总体目标

本文最终关心的量是某条边 e 在真实拓扑中出现的后验概率：

$$\mathbb{P}(e \in T \mid D). \quad (1.5)$$

它不是普通边权，也不是最大生成树算法中的分数，而是“在观察到数据 D 之后，综合所有可能拓扑，边 e 被包含在拓扑中的概率”。与只输出一棵树相比，边后验概率能指出哪些局部连接非常可信，哪些位置存在多个近似等价的替代结构，哪些边几乎没有数据支持。

说明 1.1. 当只观测末端节点且存在 hidden zero-injection nodes 时， e 可能指观测节点之间的 reduced/effective topology 边，而不一定对应一条真实物理导线。本文会反复强调这一解释边界。

第二章 贝叶斯理论基础

2.1 条件概率

贝叶斯统计从条件概率开始。若 A 和 B 是两个事件，并且 $\mathbb{P}(B) > 0$ ，则

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}. \quad (2.1)$$

式 (2.1) 的意思是：在已经知道 B 发生的前提下， A 发生的概率等于“ A 和 B 同时发生的概率”除以“ B 发生的概率”。条件概率描述的是证据到来以后，事件概率如何变化。

在配电网拓扑辨识中，可以把 A 理解为“某条候选边是正确边”，把 B 理解为“观测到一组电压和功率数据”。在没有观测数据时，我们只能依据工程经验判断边是否可信；一旦观测到某些数据，就需要重新评估该边与数据的一致性。

2.2 贝叶斯公式

由条件概率定义也有

$$\mathbb{P}(B | A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}. \quad (2.2)$$

将 $\mathbb{P}(A \cap B) = \mathbb{P}(B | A)\mathbb{P}(A)$ 代入式 (2.1)，得到贝叶斯公式：

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(B | A)\mathbb{P}(A)}{\mathbb{P}(B)}. \quad (2.3)$$

式 (2.3) 把“证据出现后的概率”表示为三个量：证据在假设 A 下出现的可能性、假设 A 的先验可信度，以及证据本身出现的总概率。

推广到连续参数 θ ，有

$$p(\theta | D) = \frac{p(D | \theta)p(\theta)}{p(D)}. \quad (2.4)$$

这里有四个核心对象：

- $p(\theta)$ 是 prior，即先验，表示观测数据前对参数的认识；

- $p(D | \theta)$ 是 likelihood，即似然，表示给定参数后观测数据出现的可能性；
- $p(\theta | D)$ 是 posterior，即后验，表示结合数据后对参数的更新认识；
- $p(D)$ 是 evidence 或 marginal likelihood，是归一化常数，使后验密度积分为 1。

2.3 先验、似然、后验的直观含义

在配电网问题中，先验可以来自工程经验：地理相邻的节点更可能相连；阻抗估计落在合理范围内的边更可信；距离矩阵短的候选边应有更高初始权重；相位不一致的节点不应被强烈支持。这些信息并不一定来自当前数据，但能在数据不足时约束解空间。

似然则由观测数据驱动。给定拓扑 T 和参数 θ_T 后，AC 潮流模型会预测末端电压。如果预测值与量测电压高度一致，则 $p(D | T, \theta_T)$ 较大；如果残差很大，则似然较小。后验把这两者结合起来：一个拓扑即使 AC 残差略小，但若严重违反工程先验，也未必获得最高后验；反过来，一个距离矩阵看似合理的拓扑，若无法解释电压，也会被数据削弱。

2.4 MAP 与 MLE

最大似然估计只考虑数据对参数的支持：

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} p(D | \theta). \quad (2.5)$$

最大后验估计则同时考虑似然和先验：

$$\hat{\theta}_{\text{MAP}} = \arg \max_{\theta} p(D | \theta)p(\theta). \quad (2.6)$$

对式 (2.6) 取负对数，得到等价的优化形式

$$\hat{\theta}_{\text{MAP}} = \arg \min_{\theta} [-\log p(D | \theta) - \log p(\theta)]. \quad (2.7)$$

这说明正则化项可以看成负对数先验。例如若 $\theta \sim \mathcal{N}(0, \sigma^2 I)$ ，则

$$-\log p(\theta) = \frac{1}{2\sigma^2} \|\theta\|_2^2 + \text{常数}, \quad (2.8)$$

因此 Gaussian prior 对应 L_2 正则。这个观点对线路参数估计很有用：阻抗不应无限大或无限小，可以通过先验把参数限制在工程合理区域。

第三章 从参数后验到拓扑后验

3.1 拓扑是离散结构变量

参数后验讨论的是连续变量 θ ，而配电网拓扑 T 是离散结构变量。若候选图 G 有许多可能生成树，则每棵树都是一个候选模型。贝叶斯公式可写成

$$\mathbb{P}(T | D) = \frac{\mathbb{P}(D | T)\mathbb{P}(T)}{\mathbb{P}(D)}. \quad (3.1)$$

其中

$$\mathbb{P}(D) = \sum_{T' \in \mathcal{T}(G)} \mathbb{P}(D | T')\mathbb{P}(T'). \quad (3.2)$$

式 (3.2) 是对所有候选拓扑求和。它的作用是归一化：所有候选树的后验概率相加必须为 1。

3.2 对线路参数的边缘化

若每棵树 T 还有未知线路参数 θ_T ，严格的拓扑似然应当把参数积分掉：

$$\mathbb{P}(D | T) = \int \mathbb{P}(D | T, \theta_T) p(\theta_T | T) d\theta_T. \quad (3.3)$$

这个积分的含义是：不是只相信某个单点参数，而是把在拓扑 T 下所有可能参数值对数据的解释能力按先验加权平均。它比单纯拟合一个最佳参数更符合贝叶斯思想，也天然惩罚过于灵活的模型。

实际中，式 (3.3) 可能难以计算。常用近似是 profile likelihood：

$$\mathbb{P}(D | T) \approx \mathbb{P}(D | T, \hat{\theta}_T), \quad (3.4)$$

其中

$$\hat{\theta}_T = \arg \max_{\theta_T} \mathbb{P}(D | T, \theta_T) = \arg \min_{\theta_T} E(T, \theta_T). \quad (3.5)$$

也就是说，对每棵候选树先拟合最能解释数据的参数，再用该最优残差评价拓扑。这个近似计算方便，但会低估参数不确定性；如果不同拓扑具有不同数量或灵活度的参数，还可能偏向更容易过拟合的模型。

第四章 AC 潮流残差如何形成似然

4.1 高斯测量噪声下的残差似然

假设末端电压量测满足

$$V_t^m = h_T(P_t^m, Q_t^m, V_{0,t}^m; \theta_T) + \varepsilon_t, \quad (4.1)$$

且

$$\varepsilon_t \sim \mathcal{N}(0, \Sigma_V). \quad (4.2)$$

若不考虑与 P, Q, V_0 相关的噪声，数据在给定 T, θ_T 下的似然满足

$$\mathbb{P}(D \mid T, \theta_T) \propto \exp \left[-\frac{1}{2} \sum_{t=1}^N \|V_t^m - h_T(P_t^m, Q_t^m, V_{0,t}^m; \theta_T)\|_{\Sigma_V^{-1}}^2 \right]. \quad (4.3)$$

这里

$$\|x\|_{\Sigma_V^{-1}}^2 = x^\top \Sigma_V^{-1} x \quad (4.4)$$

是加权二范数。若某个电压量测噪声大，则对应方差较大、权重较小；若某个节点电压量测可靠，则残差会被更重地惩罚。

定义 AC 加权残差

$$E(T, \theta_T) = \sum_{t=1}^N \|V_t^m - h_T(P_t^m, Q_t^m, V_{0,t}^m; \theta_T)\|_{\Sigma_V^{-1}}^2. \quad (4.5)$$

于是

$$\mathbb{P}(D \mid T, \theta_T) \propto \exp \left[-\frac{1}{2} E(T, \theta_T) \right]. \quad (4.6)$$

这就是“残差越小，似然越大”的数学形式。

4.2 温度参数与模型错设补偿

在真实配电网中，AC 模型可能不完美，线路参数可能未知，负荷注入可能有误差，距离矩阵也不准。此时可以引入温度或误差膨胀参数 $\tau > 0$ ：

$$\mathbb{P}(D \mid T) \propto \exp \left[-\frac{E(T)}{2\tau} \right]. \quad (4.7)$$

τ 小时, 后验更尖锐, 几乎只支持残差最小的拓扑; τ 大时, 后验更平滑, 多个残差相近的候选拓扑都能保留概率质量。

定义 4.1 (模型置信度). 由式 (4.7) 或其局部近似导出的分数, 可称为 model-based confidence。它依赖残差函数、温度参数、候选集和先验设置。它可以近似后验含义, 但只有在目标分布、噪声模型和候选空间都被正确指定时, 才可严格解释为贝叶斯后验概率。

4.3 输入变量也有误差时的 EIV 形式

若 P, Q, V_0 也存在测量误差, 可采用 errors-in-variables 形式。令 $\delta P_t, \delta Q_t, \delta V_{0,t}$ 表示对输入量测的修正, 则

$$J(T, \theta_T) = \min_{\{\delta P_t, \delta Q_t, \delta V_{0,t}\}} \sum_{t=1}^N \left(\|\delta P_t\|_{\Sigma_P^{-1}}^2 + \|\delta Q_t\|_{\Sigma_Q^{-1}}^2 + \|\delta V_{0,t}\|_{\Sigma_0^{-1}}^2 \right. \\ \left. + \left\| V_t^m - h_T(P_t^m + \delta P_t, Q_t^m + \delta Q_t, V_{0,t}^m + \delta V_{0,t}; \theta_T) \right\|_{\Sigma_V^{-1}}^2 \right). \quad (4.8)$$

式 (4.8) 的意义是: 允许输入量测在其噪声协方差许可的范围内轻微调整, 同时要求调整后的 AC 预测电压解释观测电压。这样可以避免把 P, Q, V_0 的误差全部错误归因于拓扑错误。

第五章 拓扑先验的常见形式

5.1 先验的角色

拓扑先验 $\mathbb{P}(T)$ 表示在看数据之前对候选拓扑的偏好。在配电网中，它通常不是主观臆断，而是工程知识的概率化表达。先验的强弱需要谨慎设定：如果距离矩阵可靠，可以给较大权重；如果距离矩阵来自不稳定估计，则应作为弱先验，而不是硬约束。

5.2 均匀树先验

最简单的选择是

$$\mathbb{P}(T) = \frac{1}{|\mathcal{T}(G)|}, \quad T \in \mathcal{T}(G). \quad (5.1)$$

它适合完全没有先验信息，或研究者希望让数据主导判断的情况。缺点是候选图较大时，不合理的长距离边、相位不一致边和工程上不可能的边也会获得同等初始概率。

5.3 距离矩阵先验

如果有估计距离 d_e ，可以定义

$$\mathbb{P}(T) \propto \exp\left(-\eta \sum_{e \in T} d_e\right). \quad (5.2)$$

当 $\eta = 0$ 时，距离不起作用；当 η 增大时，先验强烈偏向短距离边。若距离矩阵不准， η 应保持较小，使距离只提供软偏好。

这种形式的优点是可解释、可调节，并且可以与生成树算法兼容。它的局限是：短距离不一定代表直接电气连接，尤其在负荷相关性强、hidden nodes 多、或路径共享效应明显时，距离估计可能出现系统偏差。

5.4 阻抗、地理和工程规则先验

更一般地，可把多个工程规则写成

$$\mathbb{P}(T) \propto \exp \left[-\eta_1 \sum_{e \in T} d_e - \eta_2 \sum_{e \in T} r_e^{\text{imp}} - \eta_3 \sum_{e \in T} r_e^{\text{phase}} \right]. \quad (5.3)$$

其中 r_e^{imp} 可以惩罚阻抗范围不合理的边， r_e^{phase} 可以惩罚相位不一致的边。还可以加入地理距离、道路通道、变压器区域、开关状态记录等。关键原则是：若信息不可靠，就降低对应 η ；若信息近似确定，则可以先在候选图构造阶段删除不可能边。

第六章 边后验概率

6.1 定义

给定边事件 $e \in T$ ，边后验概率定义为

$$\mathbb{P}(e \in T \mid D) = \sum_{T \in \mathcal{T}(G): e \in T} \mathbb{P}(T \mid D). \quad (6.1)$$

它是对所有包含边 e 的候选树后验概率求和，因此是结构变量的边缘概率。

如果 $\mathbb{P}(e \in T \mid D) \approx 1$ ，说明该边在几乎所有高后验拓扑中都出现，可信度高。如果该概率约为 0.5，说明存在强替代结构，数据无法唯一决定局部连接。如果接近 0，说明数据和先验几乎都不支持该边。

6.2 边后验与边权的区别

边权 s_e 或 w_e 是输入到某个模型中的局部分数；边后验概率是对整个树空间归一化和边缘化后的结果。即使某条边的单独分数很高，也可能因为与其他高分边形成环、破坏树约束或导致 AC 残差变差而后验不高。反过来，某条边单独分数不最高，但在所有可行高质量树中稳定出现，也可能具有高边后验。

命题 6.1 (边缘化带来的全局约束). 在树结构模型中，边后验概率不仅由单条边的分数决定，还由候选图中所有其他边的竞争关系和生成树约束共同决定。

证明. 由式 (6.1) 可见， $\mathbb{P}(e \in T \mid D)$ 对所有包含 e 的树求和；这些树是否高概率取决于整棵树的分数、先验、似然和归一化常数。因此单边分数不能单独决定边后验。 $\square$

第七章 Matrix-Tree Theorem 与可分解树后验

7.1 边可加分数

若树的分数可以按边分解：

$$S(T) = \sum_{e \in T} s_e, \quad (7.1)$$

则可定义概率分布

$$\mathbb{P}(T) = \frac{\exp(S(T))}{Z} = \frac{\prod_{e \in T} \exp(s_e)}{Z}. \quad (7.2)$$

令

$$w_e = \exp(s_e) > 0, \quad (7.3)$$

则

$$\mathbb{P}(T) = \frac{\prod_{e \in T} w_e}{\sum_{T' \in \mathcal{T}(G)} \prod_{e \in T'} w_e}. \quad (7.4)$$

7.2 矩阵树定理

定理 7.1 (Matrix-Tree Theorem). 给定无向连通加权图 $G = (\mathcal{V}, \mathcal{E})$ ，边权为 $w_{ij} > 0$ 。构造加权拉普拉斯矩阵 L ：

$$L_{ij} = \begin{cases} \sum_{k \neq i} w_{ik}, & i = j, \\ -w_{ij}, & i \neq j \text{ 且 } (i, j) \in \mathcal{E}, \\ 0, & i \neq j \text{ 且 } (i, j) \notin \mathcal{E}. \end{cases} \quad (7.5)$$

删除任意第 r 行和第 r 列得到 $L^{(r)}$ ，则

$$Z = \sum_{T \in \mathcal{T}(G)} \prod_{e \in T} w_e = \det L^{(r)}. \quad (7.6)$$

矩阵树定理的意义在于：不用枚举指数数量的生成树，只需求一个 $(n-1) \times (n-1)$ 行列式，就能得到所有生成树权重乘积之和。这使得边可分解的概率树模型可以高效计算归一化常数。

7.3 边边缘概率

在边可分解模型中，边边缘概率可由

$$\mathbb{P}(e \in T) = w_e \frac{\partial \log Z}{\partial w_e} \quad (7.7)$$

给出。直观上，对某条边权 w_e 求导，会把所有包含该边的生成树项“挑出来”；再乘回 w_e 并除以 Z ，正好得到包含该边的树的总概率。

7.4 局限性

矩阵树定理要求树分数可写成边分数之和。但 AC 潮流残差

$$E_{AC}(T) = \min_{\theta_T} E(T, \theta_T) \quad (7.8)$$

通常是整棵树的全局函数。改变一条边会改变潮流路径、节点电压耦合、参数拟合和隐藏节点等效关系，不能严格写成 $\sum_{e \in T} r_e$ 。因此 Matrix-Tree 可用于距离、互信息、局部残差等近似边分数模型，却不能直接精确处理全局 AC 残差后验。

第八章 Chow-Liu Tree 与 Soft Chow-Liu

8.1 树结构概率分布

Chow-Liu tree 研究如何用树结构分布近似一个高维概率分布。给定随机变量 $X = (X_1, \dots, X_n)$ 和树 T ，若选定根节点 r ，树结构分布可写成

$$Q_T(x) = Q(x_r) \prod_{i \neq r} Q(x_i | x_{\text{pa}(i)}). \quad (8.1)$$

它也可写成无向边乘积形式：

$$Q_T(x) = \prod_i P(x_i) \prod_{(i,j) \in T} \frac{P(x_i, x_j)}{P(x_i)P(x_j)}. \quad (8.2)$$

式 (8.2) 表明，树近似只保留单变量边缘分布和树边上的二元依赖。

8.2 Chow-Liu 的目标

Chow-Liu 的目标是找一棵树，使树分布 Q_T 尽可能接近真实分布 P ：

$$T^* = \arg \min_T D_{\text{KL}}(P \| Q_T). \quad (8.3)$$

经典推导表明，这等价于

$$T^* = \arg \max_T \sum_{(i,j) \in T} I(X_i; X_j), \quad (8.4)$$

其中互信息为

$$I(X_i; X_j) = \sum_{x_i, x_j} P(x_i, x_j) \log \frac{P(x_i, x_j)}{P(x_i)P(x_j)}. \quad (8.5)$$

因此 Chow-Liu 本质上是

$$\text{互信息估计} + \text{最大权生成树}. \quad (8.6)$$

8.3 Soft Chow-Liu

如果不只输出一棵最大权树，而是希望给所有树分配概率，可定义 soft Chow-Liu:

$$\mathbb{P}(T \mid D) = \frac{\exp\left(\beta \sum_{(i,j) \in T} \hat{I}_{ij}\right)}{\sum_{T' \in \mathcal{T}(G)} \exp\left(\beta \sum_{(i,j) \in T'} \hat{I}_{ij}\right)}. \quad (8.7)$$

令

$$w_{ij} = \exp(\beta \hat{I}_{ij}), \quad (8.8)$$

即可用矩阵树定理计算归一化常数和边边缘概率。 β 控制分布尖锐程度： β 越大，概率越集中在最大互信息树附近； β 越小，树分布越平滑。

8.4 在配电网中的解释边界

Chow-Liu 学到的是统计依赖树，不一定是真实电气拓扑。配电网中两个节点的电压高度相关，可能是因为它们共享长公共路径，也可能是因为上游电压扰动、天气驱动负荷相关或用户行为相关，而不一定代表直接连线。因此 Chow-Liu 更适合作为边分数的一部分，例如提供候选边排序或先验权重，而不宜单独作为完整拓扑辨识结论。

第九章 AC 残差不可分解时的近似边概率估计

9.1 为什么不能直接用 Matrix-Tree

如果目标分布为

$$\mathbb{P}(T \mid D) \propto \exp \left[-\frac{E_{\text{AC}}(T)}{2\tau} \right] \mathbb{P}(T), \quad (9.1)$$

而 $E_{\text{AC}}(T)$ 不能按边分解，则无法把式 (9.1) 化为 $\prod_{e \in T} w_e$ 。这时矩阵树定理不能给出精确边后验。下面介绍几类可实现近似。

9.2 局部替代树 softmax

给定初始树 T^* 。对树边 $e \in T^*$ ，删除它会得到两个连通分量 A_e 和 B_e 。所有跨越这两个分量的候选替代边为

$$\mathcal{A}_e = \{f = (u, v) \in \mathcal{E}_c : u \in A_e, v \in B_e\}. \quad (9.2)$$

替代树定义为

$$T_{e \rightarrow f} = T^* - e + f. \quad (9.3)$$

计算

$$E^* = E_{\text{AC}}(T^*), \quad E_{e \rightarrow f} = E_{\text{AC}}(T_{e \rightarrow f}). \quad (9.4)$$

局部边概率可定义为

$$p_e^{\text{local}} = \frac{\exp[-E^*/(2\tau)]\mathbb{P}(T^*)}{\exp[-E^*/(2\tau)]\mathbb{P}(T^*) + \sum_{f \in \mathcal{A}_e} \exp[-E_{e \rightarrow f}/(2\tau)]\mathbb{P}(T_{e \rightarrow f})}. \quad (9.5)$$

等价地，

$$p_e^{\text{local}} = \frac{1}{1 + \sum_{f \in \mathcal{A}_e} \exp[-(E_{e \rightarrow f} - E^*)/(2\tau)] \frac{\mathbb{P}(T_{e \rightarrow f})}{\mathbb{P}(T^*)}}. \quad (9.6)$$

若所有替代树的 AC 残差都明显更大，且先验也不强烈偏向替代树，则 p_e^{local} 接近 1。它是局部、模型型置信度，不等于全局贝叶斯边后验，因为它只比较 T^* 的一跳替代树。

9.3 候选树集合归一化

另一种方法是构造候选树集合

$$\mathcal{C} = \{T^*\} \cup \{T^* - e + f\} \cup \{\text{two-swap trees}\} \cup \{\text{bootstrap trees}\}. \quad (9.7)$$

在有限集合 $\mathcal{C}$ 上定义归一化分布：

$$\tilde{\mathbb{P}}(T \mid D) = \frac{\exp[-E_{\text{AC}}(T)/(2\tau)]\mathbb{P}(T)}{\sum_{T' \in \mathcal{C}} \exp[-E_{\text{AC}}(T')/(2\tau)]\mathbb{P}(T')}, \quad T \in \mathcal{C}. \quad (9.8)$$

边概率近似为

$$\tilde{p}_e = \sum_{T \in \mathcal{C}: e \in T} \tilde{\mathbb{P}}(T \mid D). \quad (9.9)$$

这种方法比局部替代 softmax 更全局，但结果依赖候选集覆盖度。如果真实高后验树没有进入 $\mathcal{C}$ ，近似会偏乐观或偏保守。

9.4 MCMC over Trees

更接近全局后验的方法是在树空间上做 MCMC。目标分布仍为

$$\pi(T) = \mathbb{P}(T \mid D) \propto \exp[-E_{\text{AC}}(T)/(2\tau)]\mathbb{P}(T). \quad (9.10)$$

常用 proposal 是加边删边：从当前树 T 出发，随机加入一条非树边 f ，形成唯一环；再从该环中删除一条边 g ，得到新树 $T' = T + f - g$ 。

Metropolis-Hastings 接受率为

$$a(T \rightarrow T') = \min \left\{ 1, \frac{\exp[-E_{\text{AC}}(T')/(2\tau)]\mathbb{P}(T')q(T \mid T')}{\exp[-E_{\text{AC}}(T)/(2\tau)]\mathbb{P}(T)q(T' \mid T)} \right\}. \quad (9.11)$$

采样后，边概率估计为

$$\hat{p}_e^{\text{MCMC}} = \frac{1}{M} \sum_{m=1}^M \mathbf{1}\{e \in T^{(m)}\}. \quad (9.12)$$

MCMC 的优点是原则上可以探索很大的树空间，且适用于全局 AC 残差。缺点是每一步都可能需要拟合参数和计算 AC 残差，代价高；此外还要诊断混合性、burn-in、有效样本量和 proposal 是否覆盖主要后验质量区域。

第十章 Bootstrap 稳定性不是贝叶斯后验，但很有用

10.1 Block bootstrap 的思想

Bootstrap 不是先验乘似然的贝叶斯推断，而是数据扰动下算法输出稳定性的经验评估。对时序数据，不能简单独立打乱每个时刻，因为相邻时刻的负荷、电压和天气因素具有相关性。更合理的是 block bootstrap：按时间块重采样，得到

$$D^{(1)}, D^{(2)}, \dots, D^{(B)}. \quad (10.1)$$

每个重采样数据集都运行完整拓扑辨识流程：

$$D^{(b)} \rightarrow T^{(b)}, \quad b = 1, \dots, B. \quad (10.2)$$

边稳定性定义为

$$p_e^{\text{boot}} = \frac{1}{B} \sum_{b=1}^B \mathbf{1}\{e \in T^{(b)}\}. \quad (10.3)$$

10.2 解释边界

p_e^{boot} 表示在数据扰动下算法是否稳定输出边 e 。它不是严格的 $\mathbb{P}(e \in T \mid D)$ ，因为没有显式定义先验、似然和后验归一化常数。它也依赖所选算法：若算法本身有偏，bootstrap 会稳定地复现这种偏差。

但在工程上，bootstrap 非常有用。若距离矩阵估计不准，或不同时间窗口产生的边分数波动大，bootstrap 能揭示哪些边只是某个采样窗口的偶然结果。实践中可以把 p_e^{boot} 与 p_e^{local} 一起报告：前者描述数据扰动稳定性，后者描述 AC 替代结构竞争下的模型置信度。

第十一章 Score Gap 与 Replacement Edge 敏感性

11.1 最大生成树中的边敏感度

给定边分数 s_e ，最大生成树为

$$T^* = \arg \max_{T \in \mathcal{T}(G)} \sum_{e \in T} s_e. \quad (11.1)$$

对树边 $e \in T^*$ ，删除后形成两个分量 A_e, B_e 。最佳替代边为

$$f_e^* = \arg \max_{f \in \delta(A_e, B_e)} s_f, \quad (11.2)$$

其中 $\delta(A_e, B_e)$ 表示跨越两个分量的候选边集合。score gap 定义为

$$\Delta_e = s_e - s_{f_e^*}. \quad (11.3)$$

若 Δ_e 大，说明该边不容易被分数接近的边替代；若 Δ_e 小，说明局部结构存在近似等价选择。

11.2 AC 残差 gap

在 AC 残差框架中，可以定义

$$\Delta E_{e \rightarrow f} = E(T_{e \rightarrow f}) - E(T^*). \quad (11.4)$$

若所有 $\Delta E_{e \rightarrow f}$ 都为正且较大，则保留 e 更合理；若存在某条替代边 f 使 $\Delta E_{e \rightarrow f} \approx 0$ 或更小，则该局部结构不稳定。式 (9.6) 正是把这些残差差值转化为局部概率的一种方式。

第十二章 仿真校准：把置信指标转成经验正确率

12.1 从指标到经验正确率

在仿真数据中，真实拓扑 T_0 已知。可以对每条候选边构造置信特征：

$$z_e = [p_e^{\text{local}}, p_e^{\text{boot}}, \Delta E_e, \Delta s_e, d_e, r_e^{\text{flow}}, \dots]. \quad (12.1)$$

标签为

$$y_e = \mathbf{1}\{e \in T_0\}. \quad (12.2)$$

用 logistic regression 或 isotonic regression 学习

$$\hat{c}_e = \mathbb{P}(y_e = 1 \mid z_e). \quad (12.3)$$

$\hat{c}_e$ 表示：在当前仿真设定、扰动分布和算法流程下，具有这些置信特征的边真正正确的经验概率。

12.2 与贝叶斯后验的区别

simulation-calibrated correctness probability 不是同一数据集上的贝叶斯后验，而是跨仿真场景学习出的经验映射。它依赖仿真场景是否覆盖真实系统：若仿真中的负荷相关性、噪声水平、线路参数分布和 hidden-node 模式与真实系统不符，校准概率就会外推失真。

尽管如此，它具有重要工程价值。研究论文中可以同时报告三类量：贝叶斯或近似贝叶斯边概率、bootstrap 稳定性、仿真校准正确率。三者若一致给出高置信，就比单一指标更有说服力；若彼此冲突，则提示模型错设、数据扰动敏感或仿真分布不匹配。

第十三章 综合算法框架

算法 1 AC Residual-Calibrated Bayesian Edge Confidence for Radial Distribution Topology Identification

输入: 观测数据 $D = \{P_t^m, Q_t^m, V_t^m, V_{0,t}^m\}_{t=1}^N$; 候选图 $G = (\mathcal{V}, \mathcal{E}_c)$; 距离估计 d_e ; 边分数超参数 α, β, γ ; 温度 τ 。

输出: 初始树 T^* ; 每条树边的 AC-local confidence; 每条边的 bootstrap stability; 低置信边集合; 候选替代拓扑集合。

1: 对每条候选边构造初始边分数

$$s_e = -\alpha d_e - \beta r_e^{\text{local}} + \gamma I_e.$$

2: 用最大生成树算法求

$$T^* = \arg \max_{T \in \mathcal{T}(G)} \sum_{e \in T} s_e.$$

3: 在 T^* 上拟合 AC 参数 $\hat{\theta}_{T^*}$, 计算 $E(T^*)$ 。

4: **对** 每条树边 $e \in T^*$ **执行**

5: 删除 e 得到分量 A_e, B_e , 构造 replacement candidates $\mathcal{A}_e$ 。

6: **对** 每条替代边 $f \in \mathcal{A}_e$ **执行**

7: 构造 $T_{e \rightarrow f} = T^* - e + f$ 。

8: 拟合或快速更新 AC 参数, 计算 $E(T_{e \rightarrow f})$ 。

9: **end 对**

10: 用式 (9.5) 或 (9.6) 计算 p_e^{local} 。

11: **end 对**

12: 做 block bootstrap, 得到 $D^{(1)}, \dots, D^{(B)}$ 。

13: **对** 每个 bootstrap 数据集 $D^{(b)}$ **执行**

14: 重复初始打分、生成树和可选 AC 校正, 得到 $T^{(b)}$ 。

15: **end 对**

16: 用式 (10.3) 计算 p_e^{boot} 。

17: 标记低置信边, 例如 $p_e^{\text{local}} < \rho_1$ 或 $p_e^{\text{boot}} < \rho_2$ 。

18: 可选: 对低置信子图运行候选树归一化或 MCMC, 得到更细的局部后验近似。

19: **返回** $T^*, \{p_e^{\text{local}}\}, \{p_e^{\text{boot}}\}$, 低置信边集合, 候选替代拓扑集合。

13.1 算法解释

该算法的第一阶段用距离、局部残差和互信息构造可分解边分数，从而快速得到初始树。第二阶段不再把初始树当作最终答案，而是用 AC 残差比较局部替代树，给每条树边分配 model-based confidence。第三阶段通过 block bootstrap 评估数据扰动稳定性。若有仿真真值，还可在第四阶段做校准，把多个指标映射为经验正确率。

这个流程体现了本文的基本态度：距离矩阵、Chow-Liu 和生成树算法适合产生候选结构；AC 残差适合检验候选结构的物理一致性；MCMC、候选树归一化和 bootstrap 则用于表达不确定性，而不是强行把一个点估计伪装成确定拓扑。

第十四章 常见误区与解释边界

14.1 后验概率不是客观真理

贝叶斯后验依赖先验、似然和模型假设。如果电压噪声被错误建模为独立同方差，或线路参数先验过窄，后验概率也会被系统性扭曲。因此论文中应说明后验来自什么模型，而不是把它写成无条件真实概率。

14.2 距离权重不是边概率

距离矩阵不准时，不能把 $\exp(-\eta d_e)$ 或最大生成树中的边分数直接解释为边概率。它们只是先验或局部分数。真正的边概率需要考虑树约束、归一化和其他候选边竞争。

14.3 Matrix-Tree 的适用范围

Matrix-Tree 适合边分数可分解的情形。若目标包含全局 AC 潮流残差，就不能直接用它精确求边后验。可行做法是用 Matrix-Tree 处理近似边分数模型，再用 AC 残差做局部校正、候选树重加权或 MCMC。

14.4 Chow-Liu 不是物理拓扑辨识的全部

Chow-Liu 学到的是统计依赖树。统计依赖强可能来自直接电气连接，也可能来自公共路径和共同扰动。在配电网中，它更适合作为候选边生成器或边分数来源，而不是最终物理拓扑证明。

14.5 Bootstrap 稳定性不是贝叶斯后验

Bootstrap stability 衡量算法对数据扰动是否敏感。若某条边 p_e^{boot} 高，只说明在重采样窗口中算法经常输出它；若算法本身偏向错误边，它也可能稳定输出错误边。因此 bootstrap 应与 AC 残差、先验合理性和仿真校准一起解释。

14.6 Reduced topology 与真实物理线路

如果只有末端节点可观测而存在 hidden zero-injection nodes, 则观测节点上的边概率可能只是 reduced/effective topology 的边概率。举例来说, 两个末端节点在 reduced tree 中相邻, 可能代表它们通过一个未观测中间节点连接, 而不是二者之间有直接导线。

14.7 低置信边不等于算法错误

低置信边可能意味着算法失败, 也可能意味着该局部结构在当前量测条件下不可辨识。例如两个替代拓扑的 AC 残差几乎相同, 且都符合工程先验, 则诚实的输出应当是“不确定”, 而不是强行选择一个唯一答案。

第十五章 符号表

符号	含义
D	观测数据集合 $\{P_t^m, Q_t^m, V_t^m, V_{0,t}^m\}_{t=1}^N$ 。
T	一棵候选拓扑树。
$\mathcal{T}(G)$	候选图 G 上所有生成树的集合。
e	候选边或树边。
$\mathbb{P}(T)$	拓扑树先验概率。
$\mathbb{P}(T \mid D)$	给定数据后的拓扑树后验概率。
$\mathbb{P}(e \in T \mid D)$	边 e 的后验出现概率，对所有包含 e 的树后验求和得到。
$E_{AC}(T)$	在拓扑 T 下拟合参数后得到的 AC 潮流残差。
θ_T	拓扑 T 下的线路参数或其他待估计物理参数。
$h_T(\cdot)$	拓扑 T 下的 AC 潮流预测映射。
τ	温度或模型误差膨胀参数，控制残差似然的尖锐程度。
d_e	边 e 的距离估计或距离型先验特征。
s_e	边 e 的可加分数。
w_e	边权，通常 $w_e = \exp(s_e)$ 。
p_e^{local}	局部替代树 softmax 得到的 model-based confidence。
p_e^{boot}	bootstrap 重采样下边 e 被输出的稳定性频率。
$T_{e \rightarrow f}$	用替代边 f 替换树边 e 得到的候选树。
$\mathcal{C}$	用于有限归一化或重加权的候选树集合。

第十六章 总结

本文的核心逻辑可以概括为

$$\text{先验} + \text{AC 潮流似然} \Rightarrow \text{拓扑后验} \Rightarrow \text{边后验概率}. \quad (16.1)$$

先验表达工程知识，似然表达数据与物理模型的一致性，拓扑后验表达整棵树的可信程度，边后验概率则通过结构边缘化表达局部连线的不确定性。

当 AC 残差可按边分解或近似可分解时，Matrix-Tree Theorem 可以高效计算归一化常数和边边缘概率；Chow-Liu 和 soft Chow-Liu 则提供了从统计依赖到概率化树模型的经典路径。但真实配电网拓扑辨识中，AC 残差通常是全局函数，不能直接用 Matrix-Tree 精确处理。因此需要结合

$$\text{局部替代树 softmax} + \text{候选树归一化} + \text{MCMC} + \text{Bootstrap} + \text{仿真校准} \quad (16.2)$$

形成可实现的边置信度估计框架。

最后再次强调四类量的区别：Bayesian posterior probability 是在明确先验和似然后对树空间边缘化得到的概率；model-based confidence 是基于残差模型和有限比较集构造的近似置信度；bootstrap stability 是数据扰动下算法输出的稳定性；simulation-calibrated correctness probability 是在仿真真值上校准出的经验正确率。把它们并列报告并说明边界，比只给一棵树更符合配电网拓扑辨识中的不确定性现实。

参考文献

- [1] T. Bayes. An Essay towards solving a Problem in the Doctrine of Chances. *Philosophical Transactions of the Royal Society*, 1763.
- [2] C. Chow and C. Liu. Approximating discrete probability distributions with dependence trees. *IEEE Transactions on Information Theory*, 1968.
- [3] R. P. Stanley. *Enumerative Combinatorics, Volume 2*. Cambridge University Press, 1999.
- [4] W. K. Hastings. Monte Carlo sampling methods using Markov chains and their applications. *Biometrika*, 1970.
- [5] B. Efron and R. Tibshirani. *An Introduction to the Bootstrap*. Chapman and Hall, 1993.
- [6] D. Koller and N. Friedman. *Probabilistic Graphical Models: Principles and Techniques*. MIT Press, 2009.
- [7] A. J. Wood, B. F. Wollenberg, and G. B. Sheble. *Power Generation, Operation, and Control*. Wiley, 2013.