

终端负荷-only 配电网拓扑辨识中的 clade 聚合： 精确性引理、两阶段样本复杂度与 RNJ 安全半径

terminal_load_only_case33 notes

2026 年 9 月 2 日

1 引言与代码对应

本文研究 terminal_load_only_case33 项目中”一层 clade 聚合”管线的理论基础。该管线的实际代码流程为：

1. 用 AC 前推回代潮流仿真各场景终端量测(terminal_case33/models/ac_powerflow.py:171), 叠加相对高斯量测噪声(experiments/common.py:97-100);
2. 以平方电压降 $Y_i(t) = v_0^2(t) - V_i^2(t)$ 为回归目标(experiments/common.py:106, terminal_case33/estimation.py:106);
3. 多场景联合最小二乘拟合灵敏度矩阵, 再做对称化、截负与 ordered 半空间投影(terminal_case33/estimation.py:106-110, fit_projected_sensitivity);
4. 由 $\hat{R}, \hat{X}$ 构造阻抗距离与根深, RX75 模式先各自归一化再按 0.75/0.25 混合(terminal_case33/estimation.py:110-115);
5. 以 shared-path 矩阵和根深为输入运行 Rooted Neighbor Joining (RNJ)(terminal_case33/graph/rooted_neighbor_joining.py);
6. 对高置信外围 clade 做”软收缩”聚合: P/Q 列求和、平方电压经去嵌入重构为 pseudo 边界量(terminal_case33/graph/rooted_hierarchy.py:205-302), 在收缩后的主干问题上重跑估计与 RNJ, 再在各 clade 内以 pseudo 边界为局部根做二阶段辨识(terminal_case33/graph/rooted_hierarchy.py:302-315);
7. 最终候选用留出场景的 AC 预测 NLL 排序(terminal_case33/pipeline/ac_likelihood.py:522-534); oracle 指标只在实验脚本中计算, 不进入辨识回路(experiments/run_unified_topology_pipeline_sweep.py);

本文的目的是为第 6 步给出精确性引理与样本复杂度定理：在真实 clade 与线性模型下，聚合不引入任何近似误差（引理 2），同时把主干问题的有效噪声方差降低 $|C|$ 倍、把未知树尺寸从 n 降到 $n - |C| + 1$ （引理 3），从而使主干拓扑精确恢复所需的样本量约按 $|C|$ 倍下降（定理 1）。

写作原则是：所有模型假设逐一对应代码的实际行为，而不是任何.md 文档的描述。每个符号与每条假设的代码出处汇总于附录 A 的对照表；正文中首次出现时也以 file:line 标注。符号约定与系列文档 chapters/ 保持一致并避免冲突：树用 T 、每场景样本数用 m 、场景数用 S （ch04 用 T 表树、ch09 用 T 表样本数，本文只取前者）。证明为”证明思路”级别，与 docs/latent_tree_neighbor_joining_proof.tex 的风格对齐；但以下关键不等式链显式写出：lstsq 行误差集中与 union bound (§6 步骤 1)、ordered 投影的 entrywise max-norm 非扩张性（引理 4）、RX75 随机归一化因子的集中（引理 5）、直接 shared-path 分数的误差界与安全半径 (§6 步骤 3)。

2 模型与符号

2.1 树、灵敏度矩阵与阻抗距离

设配电网为一棵径向加权树 $T = (V, E)$, 根节点 0 (变电站/ slack 母线) 可观测, 终端 (用户) 节点集合 $L = \{1, \dots, n\}$, $|L| = n$; 隐藏零注入节点集合 $H = V \setminus (L \cup \{0\})$ 。记 path_{0i} 为根到节点 i 的唯一路径。

假设 1 (最小隐藏树). 所有边电阻 $r_e > 0$ 、电抗 $x_e > 0$; 除根以外的隐藏节点度数至少为 3, 度数为 2 的隐藏链已被压缩为一条等效边。

该假设与 docs/latent_tree_neighbor_joining_proof.tex 的最小隐藏树假设相同; 度数 2 的隐藏节点仅凭终端数据不可辨识 (见 §8)。

代码实际回归的灵敏度矩阵采用平方电压约定 (terminal_case33/models/lin_distflow.py:57-59 的 squared-voltage 分支乘以因子 2), 故本文直接定义

$$R_{ij} = 2 \sum_{e \in \text{path}_{0i} \cap \text{path}_{0j}} r_e, \quad X_{ij} = 2 \sum_{e \in \text{path}_{0i} \cap \text{path}_{0j}} x_e, \quad i, j \in L. \quad (1)$$

即 R_{ij} 是 i, j 根路径公共部分的电阻和 (平方电压单位)。阻抗距离为

$$d_{ij}^R = R_{ii} + R_{jj} - 2R_{ij} = 2 \sum_{e \in \text{path}(i,j)} r_e, \quad (2)$$

对应 terminal_case33/models/lin_distflow.py:63-67 impedance_distance_from_reduced_R。 d^R 是由隐藏树边权诱导的 additive tree metric。根深 (root depth) 为对角元

$$h_i := R_{ii} = 2 \sum_{e \in \text{path}_{0i}} r_e, \quad (3)$$

代码在 RX 混合模式下按同一归一化混合对角元作为根深 (terminal_case33/estimation/baseline.py:90-93)

2.2 观测模型

数据按场景组织: 场景 $s = 1, \dots, S$, 每场景样本 $t = 1, \dots, m$, 总样本数 $N = Sm$ 。每个场景是一次独立的一日运行剖面 (不同 seed、不同可再生出力剖面, 见 experiments/common.py:37-58 的场景注册表)。回归目标为平方电压降

$$Y_i^{(s)}(t) = v_0^{(s)}(t)^2 - V_i^{(s)}(t)^2, \quad (4)$$

其中根电压 v_0 被直接量测, 根电压波动在进入回归前即被去除 (terminal_case33/estimation/preprocessing_squared_voltage_drop_from_observed_root 的文档字符串明确说明这是 "preferred target")。

假设 2 (线性 drop 模型与有界模型失配). 存在场景截距 $\gamma_i^{(s)} \in \mathbb{R}$, 使得

$$Y_i^{(s)}(t) = \sum_{j \in L} R_{ij} P_j^{(s)}(t) + \sum_{j \in L} X_{ij} Q_j^{(s)}(t) + \gamma_i^{(s)} + b_i^{(s)}(t) + E_i^{(s)}(t), \quad (5)$$

其中 b 为线性 (*LinDistFlow* 平方电压近似) 模型相对 AC 潮流的有界失配项, $|b_i^{(s)}(t)| \leq \beta$ 。

式 (5) 正是代码拟合的模型:设计阵为 $[P | Q | \text{场景示性}] \in \mathbb{R}^{N \times (2n+S)}$ (`terminal_case33/estimation/multiscenario.py:106-115` 的文档字符串逐字写出 $Y_s = P_s R.T + Q_s X.T + \text{gamma}_s + \text{delta}_V_s$ 。AC 仿真(`terminal_case33/models/ac_powerflow.py:171`) 只用于生成数据与最终候选排序, 不进入本文任何定理的条件; 失配项 b 以常数偏差形式进入误差预算 (见定理 1 步骤 1), 不随样本量消失, 这是诚实处理而非技术缺陷。

假设 3 (逐终端独立的次高斯噪声). $\{E_i^{(s)}(t)\}$ 关于 (s, t, i) 相互独立, 均值为零, 次高斯参数不超过 σ_{eff}^2 。

该假设对应仿真器的事实: `experiments/common.py:97-100` 对每个量测矩阵用独立高斯扰动 $P_{\text{meas}} = P + \mathcal{N}(0, \sigma_{PQ} \cdot |P|)$ 、 $V_{\text{meas}} = V + \mathcal{N}(0, \sigma_V \cdot |V|)$, 逐终端、逐时刻独立; 电压噪声经 $(v_0^2 - V^2)$ 的差分进入 Y 时近似放大 $2V \approx 2$ 倍, 连同 P/Q 量测噪声经回归目标的贡献一起并入 σ_{eff} 。跨终端相关的后果在 §8 讨论。

2.3 估计器与 RNJ 输入

代码的估计器 (默认 `alpha=0`, 即无岭惩罚) 为

1. **lstsq**: $\hat{\Theta} = (Z^\top Z)^{-1} Z^\top Y$, $Z = [P|Q|\text{场景示性}]$ (`multiscenario.py:68`);
2. **对称化 + 截负**: $\hat{R} \leftarrow \max\{0, \frac{1}{2}(\hat{\Theta}_R^\top + \hat{\Theta}_R)\}$ (`multiscenario.py:71-73`);
3. **ordered 投影**: 循环执行对称化/截负与半空间修正 $\{M_{ii} - M_{ij} \geq \text{margin}\}$, 最后做一次对角提升可行化 (`multiscenario.py:74-82`; `matrix_constraints.py:70-96` `project_ordered_sensitivity_margin` 半空间扫描 :37-53, 可行化 :56-67; `margin = margin_ratio \times \text{median}(\text{diag})`, `margin_ratio` 默认 10^{-6} , `multiscenario.py:33`);
4. **距离诊断与直接分数**: 保留式 (2) 的估计版; RX75 模式下 RNJ 直接使用 $\hat{S}_{ij} = 0.75\hat{R}_{ij}/\hat{s}_R + 0.25\hat{X}_{ij}/\hat{s}_X$, 根深为 $\hat{H}_i = \hat{S}_{ii}$ (`sensitivity_geometry.py`);
5. **RNJ**: 以 $\hat{S}$ 最大者优先成组 (`rooted_neighbor_joining.py`), 容差 $\tau = \text{tolerance_factor} \cdot \text{median}(\hat{H})$, 默认因子 0.16 (`baseline.py:104,172`)。

设计阵 Z 的条件数由拟合例程返回并随结果审计保存 (`multiscenario.py:171` 返回 `np.linalg.cond(design)` `baseline.py:194` 的 `condition_number` 字段)。

假设 4 (设计阵良态与 `margin`)。 (1) 设计阵满足 $\sigma_{\min}(Z) \geq \sqrt{N v_{\min}}$ 、 $\sigma_{\max}(Z) \leq \sqrt{N v_{\max}}$, 记 $\kappa(Z) = \sigma_{\max}(Z)/\sigma_{\min}(Z)$; (2) 真实树最短内部边对应的阻抗距离 `margin` 为 $\ell_{\min} > 0$; (3) 真实 R 严格满足 `ordered` 可行性: 对一切 $i \neq j$, $R_{ii} - R_{ij} \geq g_{\min}$, 且 $g_{\min}$ 远大于代码投影 `margin` (10^{-6} 相对量级); (4) 每个被确认 `clade` 的 `quartet` 检测间隔至少为 $\ell_{\min}^C > 0$ (见 §6 步骤 4)。

说明 1. 假设 4(3) 对真实灵敏度矩阵自动成立: $R_{ii} - R_{ij} = 2 \sum_{e \in \text{path}_{0i} \setminus \text{path}_{0j}} r_e > 0$ 是 i 在 $\text{LCA}(i, j)$ 之下悬挂段的电阻和, 在最小隐藏树假设下严格为正。代码的投影 `margin` 为数值保护量级, 真实矩阵以很大余量可行——这一事实是引理 4 非扩张性论证的前提。

3 引理 1: 外部等价

定义 1 (悬挂 clade). 终端子集 $C \subset L$ ($2 \leq |C| < n$) 称为附着于节点 $g \in V$ 的悬挂 clade, 若 C 是 g 的某条下游子树中的全部终端, 即对任意 $j \in C$, 路径 path_{0j} 经过 g , 而任何 $i \notin C$ 的路径不经过 g 以下的 C -侧支路。收缩树 T/C 指把 C 的下游子树替换为单个 *pseudo* 终端 g 所得的树。

引理 1 (外部等价). 设 C 是附着于 g 的悬挂 clade。则对任意 $i \notin C$ 与任意 $j, k \in C$,

$$R_{ij} = R_{ik} = R_{ig}, \quad X_{ij} = X_{ik} = X_{ig}. \quad (6)$$

证明思路. 对 $i \notin C, j \in C$, 公共路径 $\text{path}_{0i} \cap \text{path}_{0j} = \text{path}_{0i} \cap \text{path}_{0g}$: j 的路径在 g 处与 i 的路径分离, g 以下的 C -侧支路对交集无贡献。右端与 j 无关, 故式 (6) 由公共路径形式 (1) 一行证得。X 同理。□

说明 2 (与代码的对应). 引理 1 的物理内容是: 簇外注入对簇内各终端的平方电压降贡献完全相同。这正是代码去嵌入步骤“只用簇内 P/Q 列”的精确依据——*terminal_case33/graph/rooted_hierarchy.py* 的注释原文为“Tree additivity makes that differential zero for injections outside the clade, so de-embedding deliberately uses only descendant P/Q columns”, 实现上差分灵敏度向量 delta_r/delta_x 只在簇内位置非零 (*rooted_hierarchy.py:274-282*)。

4 引理 2: 聚合精确性

引理 2 (一层 clade 聚合的精确性). 设 C 是附着于 g 的悬挂 clade, 观测满足假设 2 的线性模型。则:

- (a) **KCL 聚合:** *pseudo* 注入 $P_g^{(s)}(t) := \sum_{j \in C} P_j^{(s)}(t)$ 、 $Q_g^{(s)}(t) := \sum_{j \in C} Q_j^{(s)}(t)$ 恰为流过附着边 (g 与其父节点之间的边) 的总注入;
- (b) **去嵌入恒等式:** 对任意 $i \in C$, 理想去嵌入量

$$\tilde{Y}_{g,i} := Y_i - \sum_{j \in C} [R_{ij} - R_{gj}]_+ P_j - \sum_{j \in C} [X_{ij} - X_{gj}]_+ Q_j \quad (7)$$

(省略场景与样本指标) 与 $i \in C$ 无关, 记为 $\tilde{Y}_g$; 并且它恰等于收缩树 T/C 上 *pseudo* 终端 g 的 *drop* 模型

$$\tilde{Y}_g^{(s)}(t) = \sum_{j \notin C} R_{gj} P_j^{(s)}(t) + R_{gg} P_g^{(s)}(t) + \sum_{j \notin C} X_{gj} Q_j^{(s)}(t) + X_{gg} Q_g^{(s)}(t) + \gamma_g^{(s)} + \tilde{b}_g^{(s)}(t) + \tilde{E}_g^{(s)}(t), \quad (8)$$

其中 $\gamma_g^{(s)} = \gamma_i^{(s)}$ (与 $i \in C$ 无关的部分), $|\tilde{b}_g| \leq \beta$, $\tilde{E}_g$ 次高斯参数不超过 σ_{eff}^2 。即在真实 *clade* 与线性模型下, 聚合不引入任何近似误差;

- (c) **附着深度恒等式:** 若 g 在 C 内分出至少 2 支 (由假设 1 成立), 则

$$R_{gg} = \min_{\substack{j \neq k \\ j, k \in C}} R_{jk}. \quad (9)$$

证明思路. (a) 径向树上流过附着边的功率等于下游全部终端注入之和 (无损近似下即 KCL; 损耗项并入失配 b)。代码逐字实现为列求和 `p_pseudo[pseudo_id] = p_terminal[children].sum(axis=1)` (`rooted_hierarchy.py`:260-261)。

(b) 分三步。第一步 (正部截断在理想模型下不激活): 对 $i, j \in C$, $\text{path}_{0i} \cap \text{path}_{0j} \supseteq \text{path}_{0g}$, 故 $R_{ij} - R_{gj} = 2 \sum_{e \in (\text{path}_{0i} \cap \text{path}_{0j}) \setminus \text{path}_{0g}} r_e \geq 0$; $[\cdot]_+$ 可以去掉, 差值恰为 g 以下公共支路的电阻和。第二步 (与 i 无关): 把式 (5) 的 Y_i 展开, 对 $j \in C$ 的项为 $R_{ij}P_j = [R_{gj} + (R_{ij} - R_{gj})]P_j$, 去嵌入恰好消去第二项, 留下 $R_{gj}P_j$ ——与 i 无关; 对 $j \notin C$ 的项由引理 1, $R_{ij} = R_{gj}$, 本来就与 i 无关。第三步 (等于收缩树模型): 合并后 C 内项为 $\sum_{j \in C} R_{gj}P_j$ 。注意 $R_{gj} = R_{gg} + (j \text{ 在 } g \text{ 以下支路的共享电阻})$, 而理想去嵌入把 j 在 g 以下的部分全部消去, 故 $\sum_{j \in C} R_{gj}P_j$ 经 (7) 化简为 $R_{gg} \sum_{j \in C} P_j = R_{gg}P_g$ (KCL); $j \notin C$ 的项保持 $R_{gj}P_j$ 。同理。于是 $\tilde{Y}_g$ 满足收缩树 T/C 上以 g 为终端的 drop 模型 (8), 截距、失配界与噪声参数逐项继承。

(c) 对 $j \neq k \in C$, $R_{jk} = R_{gg} + 2 \sum_{e \in (\text{path}_{0j} \cap \text{path}_{0k}) \setminus \text{path}_{0g}} r_e \geq R_{gg}$; 取 j, k 分别位于 g 在 C 内的两条不同分支 (假设 1 保证至少两支), 其 g 以下公共部分为空, 等号成立。□

说明 3 (代码的含噪鲁棒版)。代码并不使用式 (7) 的理想量本身:

- 边界行 R_{gj} 用鲁棒估计: 簇内取 `clip(quantile0.2(off-diag  $R[C, C]$ ), 0, min diag  $R[C, C]$ )`, 簇外取 `median $i \in C$   $R_{ij}$` (`rooted_hierarchy.py`:182-202 `_boundary_sensitivity_row`)。由式 (9), 理想值是簇内 *off-diagonal* 的最小值; `quantile0.2` 是其抗噪替代, `min diag` 上界由 $R_{gg} \leq R_{jj}$ 保证方向正确;
- 式 (7) 对每个 $i \in C$ 计算后对子节点取 `median` (`rooted_hierarchy.py`:284), 再与簇内均值做凸混合 `mean + w · (median - mean)`, 默认 $w = 0.50$ (`rooted_hierarchy.py`:285-287; `pipeline/unified_topology_pipeline.py`:71 `aggregation_deembedding_weight=0.50`)。

引理 2(b) 给出的是这些启发式所逼近的理想不动点: 无噪时 `median`、`mean` 与任意 w 的混合都等于 $\tilde{Y}_g$, 故鲁棒版与理想恒等式相容。 w 与 `quantile` 的理论选择目前是开放问题 (§8)。

5 引理 3: 降噪与降维

引理 3 (聚合的降噪与降维)。在引理 2 的条件下, 并对 k 个互不相交的确切 *clade* $C_1, \dots, C_k$ (大小 $|C_c| \geq 2$) 同时聚合:

- 降噪:** *pseudo* 观测 $\hat{Y}_{g_c} = \frac{1}{|C_c|} \sum_{i \in C_c} \tilde{Y}_{g_c, i}$ 的噪声次高斯参数降为 $\sigma_{\text{eff}}^2/|C_c|$; 代码的 *median* 版本渐近方差为 $\frac{\pi}{2} \sigma_{\text{eff}}^2/|C_c|$ (高斯情形), 与 *mean* 的任意凸混合仍为 $O(\sigma_{\text{eff}}^2/|C_c|)$;
- 降维:** 主干回归未知量维数 $2n + S \rightarrow 2(n - \sum_c (|C_c| - 1)) + S$;
- 条件数:** 簇内 P/Q 列合并为其和, 消除了由簇内负荷同步产生的近共线方向, 最小奇异值不因簇内相关性而塌缩; 设计阵条件数由拟合例程在收缩问题上重新返回 (`multiscenario.py`:171), 作为可审计量。

证明思路. (a) 由引理 2(b), $\tilde{Y}_{g_c, i} = \tilde{Y}_g + \varepsilon_i$, 其中 ε_i 跨 $i \in C$ 独立 (假设 3: 仿真噪声逐终端独立, 去嵌入的差分项只含确定性的估计系数与量测 P/Q , 其噪声贡献为低阶项, 并入 σ_{eff})。独立

次高斯变量的均值以次高斯参数 $\sigma^2/|C|$ 集中; median 在高斯下的渐近方差为 $\pi\sigma^2/(2|C|)$; 凸混合的方差不超过两个分量的较大者 (Cauchy–Schwarz), 故仍为 $O(\sigma^2/|C|)$ 。

(b) 每个 clade 把 $|C_c|$ 个终端列替换为 1 个 pseudo 列, P 、 Q 块各减少 $|C_c| - 1$ 列, 场景示性列不变。

(c) 列子集与列求和是设计的线性聚合 $Z \mapsto ZA$; 簇内高度相关的列合并后, 原来由簇内同步负荷造成的近零奇异方向被移除 (这正是 ch05 反例 4 的病态来源, 见推论 1(ii))。一般情况下 $\sigma_{\min}(ZA)$ 不存在普适的单调性结论, 因此本文不对条件数作超出代码可审计范围的断言: 每次主干拟合返回 `np.linalg.cond(design)` (`multiscenario.py:171`), 实验层面可直接核校。 $\square$

6 定理 1: 两阶段样本复杂度

本节先给两个技术引理 (ordered 投影的非扩张性、RX75 归一化因子的集中), 再陈述并论证主定理。

引理 4 (ordered 投影链的 entrywise max-norm 非扩张性). 设真实灵敏度矩阵 R 满足 ordered 可行性 (对称、逐元非负、且对一切 $i \neq j$, $R_{ii} - R_{ij} \geq \text{margin}$, 见假设 4(3))。若输入矩阵 M 满足 $\|M - R\|_{\max} \leq \eta$, 则 `project_ordered_sensitivity_matrix` (`matrix_constraints.py:70-96`) 的每一个基本操作——对称化、非负截断、半空间修正 (`_project_diagonal_order`, :37-53)、最终对角提升可行化 (`_make_ordered_feasible`, :56-67)——输出 M' 仍满足 $\|M' - R\|_{\max} \leq \eta$ 。因此整个投影链 (任意多次迭代) 后 $\|\hat{R}^{\text{ord}} - R\|_{\max} \leq \eta$ 。

证明思路. 记 $e_{ij} = M_{ij} - R_{ij}$, $|e_{ij}| \leq \eta$ 。逐操作验证:

- (1) 对称化 $M' \leftarrow \frac{1}{2}(M + M^\top)$: 由 R 对称, $|M'_{ij} - R_{ij}| \leq \frac{1}{2}(|e_{ij}| + |e_{ji}|) \leq \eta$ 。
- (2) 非负截断 $x \mapsto \max(x, 0)$: 逐元 1-Lipschitz, 且 $R \geq 0$, 非扩张。
- (3) 半空间修正: 当 violation $v := \text{margin} - (M_{ii} - M_{ij}) > 0$ 时, 代码更新

$$M'_{ii} = M_{ii} + \frac{2}{3}v, \quad M'_{ij} = M_{ij} - \frac{1}{3}v, \quad M'_{ji} = M'_{ij}. \quad (10)$$

令 $g := (R_{ii} - R_{ij}) - \text{margin} \geq 0$ (真矩阵的可行余量), 则 $v = (e_{ij} - e_{ii}) - g$, 且 $v > 0$ 蕴含 $e_{ij} - e_{ii} > g \geq 0$ 。代入 (10):

$$M'_{ii} - R_{ii} = \frac{1}{3}e_{ii} + \frac{2}{3}e_{ij} - \frac{2}{3}g, \quad (11)$$

$$M'_{ij} - R_{ij} = \frac{2}{3}e_{ij} + \frac{1}{3}e_{ii} + \frac{1}{3}g. \quad (12)$$

对式 (11): 下界 $M'_{ii} - R_{ii} = e_{ii} + \frac{2}{3}v \geq e_{ii} \geq -\eta$ (因 $v \geq 0$); 上界 $\frac{1}{3}e_{ii} + \frac{2}{3}e_{ij} - \frac{2}{3}g \leq \frac{1}{3}e_{ii} + \frac{2}{3}e_{ij} \leq \eta$ 。
对式 (12): 下界 $\frac{2}{3}e_{ij} + \frac{1}{3}e_{ii} + \frac{1}{3}g \geq \frac{2}{3}e_{ij} + \frac{1}{3}e_{ii} \geq -\eta$; 上界利用 $g < e_{ij} - e_{ii}$, $\frac{2}{3}e_{ij} + \frac{1}{3}e_{ii} + \frac{1}{3}g < \frac{2}{3}e_{ij} + \frac{1}{3}e_{ii} + \frac{1}{3}(e_{ij} - e_{ii}) = e_{ij} \leq \eta$ 。故 $|M'_{ii} - R_{ii}| \leq \eta$ 、 $|M'_{ij} - R_{ij}| \leq \eta$; M'_{ji} 相同 ($R_{ji} = R_{ij}$)。

(4) 最终对角提升: $M'_{ii} = \max(M_{ii}, \max_{j \neq i} M_{ij} + \text{margin})$ 。设真实行余量 $g_i := R_{ii} - \max_{j \neq i} R_{ij} \geq \text{margin}$ 。下界 $M'_{ii} \geq M_{ii} \geq R_{ii} - \eta$; 上界: 若未触发提升则 $M'_{ii} = M_{ii} \leq R_{ii} + \eta$; 若触发, $M'_{ii} \leq \max_{j \neq i} R_{ij} + \eta + \text{margin} = R_{ii} - g_i + \eta + \text{margin} \leq R_{ii} + \eta$ 。故 $|M'_{ii} - R_{ii}| \leq \eta$ 。

各操作均保持 $\|\cdot - R\|_{\max} \leq \eta$, 复合后结论成立。 $\square$

说明 4. 值得注意的是, 代码的更新 (10) 并非向半空间 $\{M_{ii} - M_{ij} \geq \text{margin}\}$ 的欧氏正交投影 (那将是 $(v/2, -v/2)$), 而是 $(2v/3, -v/3)$ 的偏斜修正。上述论证表明: 在真矩阵可行 ($g \geq 0$) 且

$v \geq 0$ 的结构下, 新误差是两个旧误差的凸组合减去非负松弛项, 因此 entrywise max-norm 仍非扩张——这比”凸投影在 Frobenius 范数下非扩张”的通用结论更强, 也正是评审所要求的处理。若放松 $g \geq 0$ (真矩阵违反投影 *margin*), 非扩张性不再成立; 但由于代码 *margin* 为 10^{-6} 相对量级而真实 $g_{\min}$ 是物理边电阻量级, 该前提在实际中总是成立。

引理 5 (RX75 随机归一化因子的集中). 设事件 $\mathcal{E} = \{\|\hat{d}^R - d^R\|_{\max} \leq 4\eta_R\}$ 成立, 且 $4\eta_R < \min_{i \neq j} d_{ij}^R$. 令 $s_R := \frac{1}{n(n-1)} \sum_{i \neq j} d_{ij}^R$, $\hat{s}_R$ 为 $\hat{d}^R$ 正项均值 (*baseline.py:71-73*)。则在 $\mathcal{E}$ 上:

- (a) 正项选取是确定的: $\hat{d}^R$ 的对角元恒等于 0 (构造 (2) 使 $\hat{d}_{ii}^R \equiv 0$), 而所有 $i \neq j$ 项满足 $\hat{d}_{ij}^R \geq d_{ij}^R - 4\eta_R > 0$, 故”正项均值”恰为全体 $i \neq j$ 对的均值;
- (b) $|\hat{s}_R - s_R| \leq 4\eta_R$ ($n(n-1)$ 个各误差 $\leq 4\eta_R$ 的量的均值);
- (c) 归一化距离逐元误差

$$\left| \frac{\hat{d}_{ij}^R}{\hat{s}_R} - \frac{d_{ij}^R}{s_R} \right| \leq \frac{|\hat{d}_{ij}^R - d_{ij}^R|}{\hat{s}_R} + \frac{d_{ij}^R |\hat{s}_R - s_R|}{s_R \hat{s}_R} \leq \frac{4\eta_R}{s_R - 4\eta_R} \left(1 + \frac{d_{\max}^R}{s_R} \right), \quad (13)$$

其中 $d_{\max}^R = \max_{i \neq j} d_{ij}^R$;

- (d) 混合距离 $\hat{d} = 0.75 \hat{d}^R / \hat{s}_R + 0.25 \hat{d}^X / \hat{s}_X$ (*baseline.py:89*) 的逐元误差不超过 $0.75 c_R \eta_R + 0.25 c_X \eta_X$, $c_R = \frac{4}{s_R - 4\eta_R} (1 + \frac{d_{\max}^R}{s_R})$ 为 $O(1/s_R)$ 常数; 根深 (*baseline.py:90-93*) 同理 (正项均值换为对角均值)。

证明思路. (a)(b) 已在上式给出; (c) 是标准的”商扰动”展开, $|\hat{d}/\hat{s} - d/s| \leq |\hat{d} - d|/\hat{s} + (d/s) \cdot |\hat{s} - s|/\hat{s}$, 并用 $\hat{s}_R \geq s_R - 4\eta_R$; (d) 对两个归一化项分别用 (c) 再以权重凸组合。结论: 主定理对未归一化距离陈述; RX75 归一化只是把 η 换成 $\eta' = O(\eta/s_R)$, 只改变常数, 不改变样本复杂度的阶。□

定理 1 (两阶段样本复杂度). 在假设 1-4 下, 设对 $\delta \in (0, 1)$,

$$\eta := \underbrace{\frac{\sigma_{\text{eff}} \sqrt{2 \log(4n(2n+S)/\delta)}}{\sigma_{\min}(Z)}}_{\text{噪声项, } \asymp \sigma_{\text{eff}} \kappa(Z) \sqrt{\frac{\log(n/\delta)}{N v_{\max}}}} + \underbrace{\frac{\beta \sqrt{N}}{\sigma_{\min}(Z)}}_{\text{模型失配偏差 (不随 } N \text{ 消失)}} \quad (14)$$

满足 RNJ 安全半径条件 (式 (22)) 与 *quartet* 检测条件 (式 (23))。则以概率 $\geq 1 - \delta - \delta_q$:

- (a) *ordered* 投影后的估计满足 $\|\hat{R}^{\text{ord}} - R\|_{\max} \leq \eta$ (X 同理);
- (b) RNJ 在收缩树 $T/\{C_c\}$ 上精确恢复主干拓扑;
- (c) 条件于所有确认 *clade* 为真, 两阶段管线 (聚合主干 + 各 *clade* 局部二阶段) 精确恢复完整拓扑; 主干阶段的有效噪声方差为 $\sigma_{\text{eff}}^2/|C|$ 、未知树尺寸为 $\tilde{n} = n - \sum_c (|C_c| - 1)$, 故主干精确恢复所需总样本量

$$N = Sm \gtrsim \frac{\sigma_{\text{eff}}^2 \kappa(\tilde{Z})^2 \log(\tilde{n}/\delta)}{|C| \cdot v_{\max} \cdot \tilde{\gamma}^2} \quad (15)$$

相对未聚合管线 ($|C| = 1, \tilde{\gamma} = \gamma_{\min}$ 含簇内短边) 约按 $|C|$ 倍下降, 且收缩树 *margin* $\tilde{\gamma} = \tilde{\ell}_{\min}$ 不再受簇内短边限制。

证明思路. 步骤 1 (lstsq 行误差集中 + union bound)。对每个目标列 j (终端 j 的 Y 列),

$$\hat{\Theta}_{\cdot j} - \Theta_{\cdot j} = (Z^\top Z)^{-1} Z^\top (E_{\cdot j} + b_{\cdot j}). \quad (16)$$

其第 k 个系数为 $a_k^\top (E_{\cdot j} + b_{\cdot j})$, 其中 $a_k^\top$ 是 $(Z^\top Z)^{-1} Z^\top$ 的第 k 行, $\|a_k\|_2 \leq \sigma_{\max}((Z^\top Z)^{-1} Z^\top) = 1/\sigma_{\min}(Z)$ 。由假设 3, $a_k^\top E_{\cdot j}$ 是次高斯参数 $\leq \sigma_{\text{eff}}^2/\sigma_{\min}^2(Z)$ 的零均值变量:

$$\Pr(|a_k^\top E_{\cdot j}| > t) \leq 2 \exp\left(-\frac{t^2 \sigma_{\min}^2(Z)}{2\sigma_{\text{eff}}^2}\right); \quad |a_k^\top b_{\cdot j}| \leq \|a_k\|_2 \|b_{\cdot j}\|_2 \leq \frac{\beta \sqrt{N}}{\sigma_{\min}(Z)}. \quad (17)$$

对全部 R 、 X 块系数 (2 块 $\times n$ 列 $\times (2n + S)$ 行, 共 $2n(2n + S)$ 个 entry) 做 union bound:

$$\Pr\left(\max_{k,j} |\hat{\Theta}_{kj} - \Theta_{kj}| > t + \frac{\beta \sqrt{N}}{\sigma_{\min}(Z)}\right) \leq 4n(2n + S) \exp\left(-\frac{t^2 \sigma_{\min}^2(Z)}{2\sigma_{\text{eff}}^2}\right). \quad (18)$$

令右端等于 δ 解出 t , 即得式 (14) 的 η ; 用 $\sigma_{\min}(Z) = \sigma_{\max}(Z)/\kappa(Z) \asymp \sqrt{N v_{\max}}/\kappa(Z)$ 改写成右端的形式。对称化与截负不放大 max-norm (引理 4 的步骤 (1)(2)), 再由引理 4 整个 ordered 投影链保持 $\|\hat{R}^{\text{ord}} - R\|_{\max} \leq \eta$, 即结论 (a)—— η 界覆盖代码的真实估计器输出, 而非仅 lstsq 中间量。

步骤 2 (距离误差 $\leq 4\eta$, ch09 链)。由式 (2) 的构造,

$$\begin{aligned} |\hat{d}_{ij} - d_{ij}| &= |(\hat{R}_{ii} - R_{ii}) + (\hat{R}_{jj} - R_{jj}) - 2(\hat{R}_{ij} - R_{ij})| \\ &\leq \eta + \eta + 2\eta = 4\eta. \end{aligned} \quad (19)$$

RX75 模式下由引理 5, 把 4η 换成 $O(\eta/s_R)$ 的归一化版本, 以下推导不变 (常数因子)。

步骤 3 (直接 shared-path 分数的安全半径)。RNJ 不再从 $\hat{d}$ 回算一个新的 $\hat{\rho}$, 而是直接输入

$$\hat{S}_{ij} = 0.75 \frac{\hat{R}_{ij}}{\hat{s}_R} + 0.25 \frac{\hat{X}_{ij}}{\hat{s}_X}, \quad \hat{H}_i = \hat{S}_{ii}. \quad (20)$$

记归一化矩阵元素误差界为 $\varepsilon_R, \varepsilon_X$, 则

$$\|\hat{S} - S\|_{\max} \leq 0.75\varepsilon_R + 0.25\varepsilon_X =: \varepsilon_S. \quad (21)$$

设相邻隐藏分叉深度的最小差为 $\ell_{\min}$ 。RNJ 的最大对选择与 family 扩展都只比较 S 值; 与当前代码一致的充分安全区间为

$$\varepsilon_S < \frac{\ell_{\min}}{4}, \quad 2\varepsilon_S \leq \tau < \ell_{\min} - 2\varepsilon_S. \quad (22)$$

旧稿的 3η 来自把同一矩阵产生的根深和距离误差当作独立项; 直接式 (20) 表明该放大不存在。代码取 $\tau = 0.16 \cdot \text{median}(\hat{H})$ (baseline.py), 其实现文档自述这是数值阈值而非理论校准 (rooted_neighbor_joining.py:95-101), 见 §8。

步骤 4 (两阶段: 条件于确认 clade 为真)。设确认 clade 集合全真的事件为 $\mathcal{E}_{\text{clade}}$, $\Pr(\mathcal{E}_{\text{clade}}) \geq 1 - \delta_q$ 。clade 检测的正确性由 quartet/四点检验单独保证: 对候选 clade C , 四点条件

$$d(i, k) + d(j, l) - \max\{d(i, j) + d(k, l), d(i, l) + d(j, k)\} \geq 2\ell_{\min}^C, \quad i, j \in C, k, l \notin C, \quad (23)$$

的每个三点和涉及至多 6 个距离项, 误差 $\leq 3 \times 4\eta = 12\eta$ (保守取 $\leq 8\eta$ 的两倍界), 对全部 $O(n^4)$ 个四元组做 union bound (失败预算 δ_q), 即得: 当 η 满足式 (22) 且 $12\eta < \ell_{\min}^C$ 时 δ_q 可控。代码对应为

`terminal_case33/graph/quartet_significance.py` 的 bootstrap 显著性检验 (20 次重复、置信水平 0.90、正支持率阈值 0.80, `pipeline/unified_topology_pipeline.py:59-62`), 以及门控管线 (`support ≥ 0.875`、boundary margin $≥ 0.10$ 、长度比 $≥ 0.02$ 、簇大小 $≤ 5$, `pipeline/peripheral_edge_proposals.py:250-254`) 加四源外部确认 (Ordered base / GTLS $≥ 0.5$ / AC / quartet, `pipeline/unified_topology_pipeline.py:250-254`).

在 $\mathcal{E}_{\text{clade}}$ 上, 由引理 2, 聚合后的主干数据恰好服从收缩树 $T/\{C_c\}$ 上的同类线性模型, 未知树尺寸 $\tilde{n} = n - \sum_c(|C_c| - 1)$; 由引理 3, pseudo 终端的有效噪声参数为 $\sigma_{\text{eff}}^2/|C_c|$ 。对主干问题重新应用步骤 1-3: 式 (14) 中 $\sigma_{\text{eff}}^2 \mapsto \sigma_{\text{eff}}^2/|C|$ 、 $n \mapsto \tilde{n}$ 、margin $\ell_{\min} \mapsto \tilde{\ell}_{\min}$ (收缩树的 margin, 不再包含簇内短边), 解出式 (15)。局部二阶段以 pseudo 边界电压为局部根电压 (`rooted_hierarchy.py:305-340 build_local_cluster_scenarios`; 或直接在 shared-path 上重 Rooted 后局部重跑 RNJ, `rooted_hierarchy.py:343-386`), 问题规模仅为 $|C_c|$, 其样本需求相对主干可忽略。主干与局部结果经 `expand_pseudo_clades_with_local_reidentification` (`rooted_hierarchy.py:407-424`) 合并为完整终端 clade 集合。对失败事件取并, 总失败概率 $≤ \delta + \delta_q$ 。□

7 推论

推论 1 (聚合的三项结构性结论). 在定理 1 的条件下:

- (i) **真实 clade 下聚合单调不伤**. 三个通道分别成立: (i) 方差通道——主干 pseudo 观测噪声 $\sigma_{\text{eff}}^2 \rightarrow \sigma_{\text{eff}}^2/|C|$ (引理 3(a)); (ii) 维数通道——未知量 $2n+S \rightarrow 2\tilde{n}+S$, $\tilde{n} < n$ (引理 3(b)), 集中不等式 (18) 的 union bound 因子同步缩小; (iii) margin 通道——收缩树 $\tilde{\ell}_{\min} ≥ \ell_{\min}$, 安全半径条件 (22) 只会更容易满足。这解释了代码的“软收缩”设计: 聚合候选始终以未聚合形式保留在候选集中 (beam 结构, `pipeline/unified_topology_pipeline.py:337-360`), 最终由留出场景 AC NLL 仲裁 (`ac_likelihood.py:522-534`), 因此聚合在最坏情形下不后退, 在定理条件下严格受益。
- (ii) **主干恢复对簇内负荷相关免疫**. *ch05* 反例 4 (同步负荷曲线) 表明: 同支路终端的 P/Q 曲线高度相关会使设计阵近共线、 $\sigma_{\min}(Z)$ 塌缩, *lstsq* 系数的 entrywise 误差按 $1/\sigma_{\min}(Z)$ 放大 (式 (17))。聚合把簇内相关列合并为单列和 $P_g = \sum_{j \in C} P_j$ (引理 2(a)), 簇内相关性不再进入主干设计阵 $\tilde{Z}$; 因此主干阶段的 $\kappa(\tilde{Z})$ 与 η 界对簇内负荷相关免疫。反例由此从“管线失效模式”转化为“聚合的收益来源”。
- (iii) **门限的定量解释**. 代码门控 (`support ≥ 0.875` 等, `peripheral_edge_proposals.py:343-345`) 是 $\Pr(\text{clade 为真} \mid \text{数据})$ 的 bootstrap 经验估计; 定理 1 给出“何时该聚合”的定量判据方向: 当 η 已小于簇内可分辨 margin (quartet 条件 (23) 满足) 而仍大于收缩树安全半径所需水平时, 聚合把 η 有效降低 $\sqrt{|C|}$ 倍并把 margin 放松到 $\tilde{\ell}_{\min}$, 恰好覆盖这一 regime; 门控 support 阈值应对应 $1 - \delta_q$ 的检测置信度。

8 假设与局限

1. **线性模型 vs AC**. 定理的回归模型是 LinDistFlow 平方电压近似 (假设 2); AC 非线性以有界失配项 $\beta\sqrt{N}/\sigma_{\min}(Z) = O(\beta/\sqrt{v_{\min}})$ 进入 η (式 (14)), 不随样本量消失。若 β 项接近

- $\ell_{\min}/6$, 安全半径条件 (22) 无论多少样本都无法满足。AC 模型在管线中只用于最终候选排序 (`ac_likelihood.py:522-534`), 不进入定理。
2. **跨终端误差相关**。引理 3(a) 的 $\sigma^2/|C|$ 依赖噪声跨终端独立 (假设 3)。若簇内噪声两两相关系数平均为 $\bar{\rho}$, 均值方差退化为 $\frac{\sigma^2}{|C|}(1 + (|C| - 1)\bar{\rho})$, $\bar{\rho} \rightarrow 1$ 时降噪收益消失。仿真器中噪声逐终端独立 (`experiments/common.py:97-100`), 且根电压公共模态已被 drop 目标去除 (`preprocessing.py:38-56`), 故在本文实验设置下假设成立; 真实智能电表的共模扰动需在部署前单独检验。
 3. **度 2 隐藏链**。度数 2 的隐藏节点在终端距离下不可辨识, 假设 1 不可去除; 聚合引理对此无修复作用。
 4. **启发式参数暂无理论**。去嵌入 median/mean 混合权重 $w = 0.50$ (`unified_topology_pipeline.py:71`)、边界行 $\text{quantile}_{0.2}$ (`rooted_hierarchy.py:191-194`)、RNJ 容差因子 0.16 (`baseline.py:104`) 均为鲁棒启发式; 引理 2 只保证它们在无噪极限下与理想恒等式一致。
 5. **目标单调精化循环不在集中不等式覆盖内**。代码默认在 `lstsq+` 投影后再跑 50 步带回溯线搜索的投影梯度精化 (`multiscenario.py:34, 138-166`), 该循环只保证最小二乘目标单调下降, 其输出的 entrywise max-norm 误差没有定理 1 步骤 1 的显式界; 定理严格覆盖的是 `constraint_refine_iterations=0` 的估计器。此外 `daily_demean` 预处理 (`baseline.py:100` 默认) 在日块内引入弱时间相关, 步骤 1 的独立性假设把它近似忽略。
 6. **clade 检测条件的独立性**。定理 1 以 $\mathcal{E}_{\text{clade}}$ 为条件; quartet 检验的有限样本功效 (而不仅是 I 类错误) 没有显式给出, 对应的 bootstrap 实现 (`graph/quartet_significance.py`) 是经验校准的。
 7. **相图实验的反面证据 (2026-07-21, 144 条件)**。配套相图实验 (`experiments/run_aggregation_phase_diag`) 结果见 `outputs/agg_phase_figures/report.md` 表明: 在链式骨干的 `grid16_k2/k4/k8` 案例上, 聚合开/关的统一管线 F1 配对增益在全部 72 对中严格为 0——聚合簇能被提议并通过稳定性门控, 但聚合候选在 `pseudo` 主干重辨识的质量门控处被拒并回退。其直接原因是链式骨干的累计阻抗使设计阵病态 (实测条件数 $\approx 2.2 \times 10^4$), 违反假设 4 的良态要求, 定理 1 的样本复杂度结论在该 regime 下不提供保证; 门控回退保护了最终结果, 恰为推论“单调不伤”提供了实证 (对照案例 `flynn16` 上聚合 14/18 条件实际应用且 F1 无损)。这意味着定理预测的正增益只应在满足设计阵良态假设的 regime 中出现; 病态 regime 下门控阈值的自适应标定是开放问题。

A 符号与代码对照表

下表汇总本文每个符号、每条假设对应的代码位置 (行号以写作时的代码为准)。所有路径相对于 `terminal_load_only_case33/`。

符号 / 假设	代码位置	说明
相对高斯量测噪声 (假设 3)	experiments/common.py:97-100	$P_{\text{meas}} = P + \mathcal{N}(0, \sigma_{PQ} P)$ 等, 逐终端独立
drop 目标 $Y = v_0^2 - V_i^2$ (式 (4))	experiments/common.py:106;	根电压公共模式预先去除
AC 前推回代仿真 (仅数据生成与排序)	terminal_case33/estimation/preprocessing.py:38-56	
$R_{ij} = 2 \sum r_e$ (式 (1))	terminal_case33/models/ac_powerflow.py:134-136	电压约定 $\times 2$: :57-59
设计阵 $Z = [P Q]$ 场景示性 (假设 2)	terminal_case33/estimation/multiscenario.py:47-59	字符串见 baseline.py:106-115
lstsq (步骤 1)	terminal_case33/estimation/multiscenario.py:68	无岭惩罚
对称化 + 截负	terminal_case33/estimation/multiscenario.py:71	步骤 (1)(2)
ordered 投影 (引理 4)	multiscenario.py:74-82;	半空间修正 :37-53; 对角提升 :56-67; margin 比 10^{-6} :
	matrix_constraints.py:70-96	multiscenario.py:33
目标单调精化循环 (局限 5)	terminal_case33/estimation/multiscenario.py:138-146	回溯搜索保证目标不升
设计阵条件数 (假设 4)	terminal_case33/estimation/multiscenario.py:141	$\text{alg.cond}(\text{design})$, 随结果审计保存
$d_{ij} = R_{ii} + R_{jj} - 2R_{ij}$ (式 (2))	terminal_case33/models/lin_distflow.py:63-67	恒为 0 (引理 5(a))
RX75 直接分数与根深 (引理 5)	terminal_case33/graph/sensitivity_geometry.py	正项均值归一, 0.75/0.25 混合
shared-path $S = c_R R + c_X X$ (式 (20))	terminal_case33/graph/sensitivity_geometry.py	RNJ 的直接输入
RNJ 主算法 (步骤 3)	terminal_case33/graph/rooted_neighbor_joining.py:138-142-149	簇扩展判断
RNJ 容差 $\tau = 0.16 \cdot \text{median}(\hat{H})$	terminal_case33/estimation/baseline.py:104	阈值, 非理论校准
clade 提取 rooted_clades	terminal_case33/graph/rooted_hierarchy.py:84-111	下游终端 clade
边界行 $\text{quantile}_{0.2}$ (式 (9)) 的鲁棒替代)	terminal_case33/graph/rooted_hierarchy.py:182-202	:191-194; clip 上界 min diag
去嵌入” 只用簇内 P/Q 列” (引理 1)	terminal_case33/graph/rooted_hierarchy.py:218	实现 :274-282
$P_g = \sum_{j \in C} P_j$ (引理 2(a))	terminal_case33/graph/rooted_hierarchy.py:260-261	簇内求和
去嵌入 + median + λ 混合 (引理 2(b))	terminal_case33/graph/rooted_hierarchy.py:272-287	:284; 混合 :285-287
$\lambda = 0.50$ 默认 (局限 4)	terminal_case33/pipeline/unified_topology_aggregation.py:71	
局部二阶段 (步骤 4)	terminal_case33/graph/rooted_hierarchy.py:305-340	边界 343 另部根
clade 展开合并	terminal_case33/graph/rooted_hierarchy.py:407-424	局部 clade 合并
门控 support ≥ 0.875 等 (推论 1(iii))	terminal_case33/pipeline/peripheral_edges_proposal.py:135-149	长边 $\geq 0.90.02$, 簇 ≤ 5
四源外部确认 (步骤 4)	terminal_case33/pipeline/unified_topology_pipeline.py:250-254, 302-334	AC / quartet
quartet 显著性检验 (式 (23))	terminal_case33/graph/quartet_significance.py	bootstrap 四点检验 (注意: 位于 graph/ 而非 estimation/)
留出场景 AC NLL 排序	terminal_case33/pipeline/ac_likelihood.py:122-134	仅最终仲裁
oracle 指标 (仅实验)	experiments/run_unified_topology_pipeline_step.py:75-79	不涉识别回路

参考文献

参考文献

- [1] K. Atteson, The performance of neighbor-joining algorithms of phylogeny reconstruction, *COCOON 1997*, Lecture Notes in Computer Science 1276.
- [2] N. Saitou and M. Nei, The neighbor-joining method: a new method for reconstructing phylogenetic trees, *Molecular Biology and Evolution*, 4(4):406–425, 1987.
- [3] R. Mihaescu, D. Levy, and L. Pachter, Why neighbor-joining works, arXiv:cs/0602041, 2006.
- [4] M. J. Choi, V. Y. F. Tan, A. Anandkumar, and A. S. Willsky, Learning latent tree graphical models, arXiv:1009.2722, 2010.
- [5] D. Deka, S. Backhaus, and M. Chertkov, Learning topology of distribution grids using only terminal node measurements, arXiv:1608.05031, 2016.