

终端量测配电网拓扑辨识主线： 完整数学证明、修正后的样本复杂度与可证明性边界

基于 `terminal_load_only_case33` 当前实现的审计稿

2026 年 9 月 1 日

目录

1	证明范围与结论分级	2
2	树模型、路径矩阵与平方电压方程	3
2.1	基本对象	3
2.2	从 DistFlow 到 reduced sensitivity	3
2.3	矩阵物理结构	4
3	加性距离、RX 混合与规范化树的唯一性	5
3.1	距离诊断和直接 shared-path 分数	5
3.2	四点定理与唯一性	5
4	多场景回归的有限样本误差	6
4.1	固定设计模型	6
4.2	ordered 投影链	7
4.3	随机归一化与 shared-path 误差的正确预算	8
5	当前 general-tree RNJ 的严格恢复条件	8
5.1	分叉间隔	8
6	quartet clade 证据的正确公式与鲁棒半径	10
7	一层 clade 聚合的精确恒等式	10
7.1	外部等价	10
7.2	pseudo 功率与边界电压	11
7.3	含量测误差时的精确传播式	12
8	两阶段恢复：正确的条件定理与样本复杂度	12
8.1	clade 集合的分解	12
8.2	stagewise 有限样本界	13

1 证明范围与结论分级2

9 固定候选树上的参数重估13

9.1 树参数化13

9.2 固定权重 NNLS 与 IRLS 边界14

10 GTLS、EIV predictive likelihood 与有限候选后验14

10.1 可分离 GTLS 的 SVD 推导14

10.2 EIV predictive variance15

10.3 有限候选 generalized posterior15

11 现有主线的端到端条件定理16

12 代码对应与可执行审计清单16

13 结论17

摘要

本文对当前“根电压校正 → 约束灵敏度估计 → RX75 加性距离 → 已知根 RNJ → quartet/NJ/RG 外周 clade → 一层 pseudo 聚合与局部重辨识 → 固定树 EIV/AC 留出排序”主线给出逐步数学证明。证明严格区分三类结论：(i) 在径向零注入树和线性平方电压模型下成立的恒等式；(ii) 在明确统计假设和校准容差下成立的有限样本定理；(iii) 当前代码中的鲁棒启发式，它们只能获得条件性解释，不能被写成无条件保证。

审计发现并修正了旧理论稿中的四个关键问题：第一，RNJ 的 shared-path 分数可直接由 R/X 元素构造，不应先形成距离再代数消去回原矩阵，也不存在旧稿给出的 3η 放大；第二，当前 RNJ 实现的安全条件应同时控制“选对最深家族、纳入全部兄弟、排除外部节点和在根处停止”，一个充分区间是 $2\varepsilon \leq \tau < \lambda_* - 2\varepsilon$ ；第三，正确 quartet gap 是“两条 cross-sum 的较小者减 within-sum”，旧稿中的 $\max$ 公式在真树上反而为零；第四，pseudo 电压平均只有在忽略 P/Q 自变量误差和共模误差时才有 $1/|C|$ 方差缩减，生产管线不能无条件宣称样本复杂度按 $|C|$ 倍下降。

1 证明范围与结论分级

当前代码包含候选生成、统计稳定性、物理重估和留出选择多个层次。为避免把经验规则误写成定理，本文采用下列分级。

模块	结论级别	本文结论
径向 LinDistFlow 共享路径矩阵	恒等式	在零注入内部节点、终端注入和一阶无损模型下严格成立。
RX75 归一化混合	恒等式	两个同拓扑树度量的正线性组合仍是同拓扑树度量。
最小隐藏树可辨识性	定理	精确加性距离与已知根深唯一确定规范化根向树。
OLS 与 ordered 投影	条件定理	固定设计、条件次高斯误差、无 EIV 偏差、关闭后续 refinement 时有显式界。

当前 general-tree RNJ	条件定理	shared-path 误差和容差落在显式安全区间时精确恢复。
quartet clade 检验	确定性定理	正确 gap 公式及其 ℓ_∞ 扰动半径可严格证明。
clade 聚合/去嵌入	恒等式	真 clade、真灵敏度、线性无损模型下严格；AC 损耗进入模型失配。
pseudo 降噪与样本复杂度	条件推论	只有额外的独立响应噪声、无 EIV/共模误差等条件下才出现 $1/ C $ 。
固定树非负参数重估	凸子问题	权重固定时是凸 NNLS；权重依赖参数的 IRLS 全局最优性不保证。
GTLS SVD	条件定理	仅对可分离、列同方差、正确白化的 TLS 模型严格。
有限候选 generalized posterior	定义与一致性	正确归一化；若真树在候选池且留出损失有正 gap，则渐近集中。
bootstrap/NJ/RG/AC gates	经验诊断	可证明 Monte Carlo 频率误差，不能证明“稳定即正确”。

因此“完整证明”的含义不是为每个默认超参数制造不存在的保证，而是把所有可证明链条闭合，并明确指出保证在何处停止。

2 树模型、路径矩阵与平方电压方程

2.1 基本对象

设 $T = (V, E)$ 是以已知节点 0 为根的有限树。观测终端集合为 $L = \{1, \dots, n\}$ ，隐藏内部节点集合为 $H = V \setminus (L \cup \{0\})$ 。对边 e ，令 $r_e > 0, x_e > 0$ 。令

$$A_{ie} := \mathbf{1}\{e \in \mathcal{P}(0, i)\}, \quad A \in \{0, 1\}^{n \times |E|}, \quad (1)$$

即 A 是 terminal-to-edge 根路径矩阵。删去边 e 后不含根的一侧所含终端记为 C_e ，于是 $A_{ie} = \mathbf{1}\{i \in C_e\}$ 。

假设 2.1 (规范化最小根向树)。所有物理终端均为叶节点；所有隐藏内部节点为零注入；非根隐藏节点度数至少为 3；零阻抗内部边已收缩；度数为 2 的隐藏链已替换为一条总阻抗相同的等效边。

最后两项不是算法便利，而是 terminal-only 可辨识性的必要规范化，见命题 3.5。

2.2 从 DistFlow 到 reduced sensitivity

令负荷消耗为正。对有向边 $e = (u \rightarrow v)$ ，记流向下流的有功、无功为 P_e, Q_e ，节点电压幅值平方为 $w_u = |V_u|^2$ 。精确单相 DistFlow 电压方程为

$$w_u - w_v = 2(r_e P_e + x_e Q_e) - (r_e^2 + x_e^2) \ell_e, \quad \ell_e = \frac{P_e^2 + Q_e^2}{w_u}. \quad (2)$$

在线性无损近似中，忽略 ℓ_e 及支路损耗，且

$$P_e = \sum_{j \in C_e} p_j, \quad Q_e = \sum_{j \in C_e} q_j. \quad (3)$$

定理 2.2 (平方电压 reduced sensitivity 恒等式). 在式 (3) 的线性无损模型下, 终端平方电压降 $y_i = w_0 - w_i$ 满足

$$y = Rp + Xq, \quad R = 2A \operatorname{diag}(r)A^\top, \quad X = 2A \operatorname{diag}(x)A^\top. \quad (4)$$

等价地,

$$R_{ij} = 2 \sum_{e \in \mathcal{P}(0,i) \cap \mathcal{P}(0,j)} r_e, \quad X_{ij} = 2 \sum_{e \in \mathcal{P}(0,i) \cap \mathcal{P}(0,j)} x_e. \quad (5)$$

证明. 沿根到 i 的路径对式 (2) 的线性部分求和:

$$\begin{aligned} y_i &= 2 \sum_{e \in \mathcal{P}(0,i)} (r_e P_e + x_e Q_e) \\ &= 2 \sum_{e \in \mathcal{P}(0,i)} \left(r_e \sum_{j \in C_e} p_j + x_e \sum_{j \in C_e} q_j \right) \\ &= \sum_{j \in L} \left(2 \sum_{e \in \mathcal{P}(0,i)} r_e \mathbf{1}\{j \in C_e\} \right) p_j + \sum_{j \in L} \left(2 \sum_{e \in \mathcal{P}(0,i)} x_e \mathbf{1}\{j \in C_e\} \right) q_j. \end{aligned}$$

条件 $j \in C_e$ 等价于 $e \in \mathcal{P}(0,j)$, 故两个括号分别为式 (5)。矩阵形式由 $(A \operatorname{diag}(r)A^\top)_{ij} = \sum_e r_e A_{ie} A_{je}$ 立即得到。□

说明 2.3 (AC 数据中的模型失配). 生产实验用 *AC backward-forward sweep* 生成电压, 而非用式 (4) 生成。把式 (2) 的 $(r_e^2 + x_e^2)\ell_e$ 、有损 *KCL*、调压设备、*ZIP*/不平衡效应与量测误差合并, 实际回归是

$$Y_s = P_s R^\top + Q_s X^\top + \mathbf{1}\gamma_s^\top + B_s + E_s. \quad (6)$$

因此后文的有限样本结论都显式保留有界偏差 B_s , 并不把 *AC* 数据误称为精确线性数据。

2.3 矩阵物理结构

命题 2.4 (对称、非负、PSD 与 ordered 性). 在假设 2.1 下, R 与 X 均对称、逐元非负、半正定, 且对 $i \neq j$,

$$R_{ii} - R_{ij} = 2 \sum_{e \in \mathcal{P}(0,i) \setminus \mathcal{P}(0,j)} r_e > 0, \quad R_{jj} - R_{ij} > 0, \quad (7)$$

X 同理。

证明. 对称与逐元非负由式 (5) 直接得到。对任意 $z \in \mathbb{R}^n$,

$$z^\top R z = 2z^\top A \operatorname{diag}(r)A^\top z = 2 \sum_{e \in E} r_e \left(\sum_{i \in C_e} z_i \right)^2 \geq 0,$$

故 $R \succeq 0$ 。由于 i, j 均为不同叶节点, i 在 $\operatorname{LCA}(i, j)$ 以下至少有一条正电阻边不属于 j 的根路径, 因此式 (7) 严格为正。 X 的证明相同。□

说明 2.5 (逆 *M-matrix* 的来源). 若对所有非根节点构造完整灵敏度矩阵, 则其一半是 *grounded Laplacian* 的逆。只保留终端的主子矩阵后, 其逆是对隐藏节点做 *Schur* 补得到的 *Kron-reduced grounded Laplacian*, 因而具有非正非对角元。该性质是 *tree-covariance* 诊断的依据; 但是代码中的交替 *PSD/ordered* 投影并非精确投到“所有树矩阵”的集合, 不能由此推出估计矩阵必对应某棵树。

3 加性距离、RX 混合与规范化树的唯一性

3.1 距离诊断和直接 shared-path 分数

定义

$$d_{ij}^R := R_{ii} + R_{jj} - 2R_{ij}, \quad h_i^R := R_{ii}. \quad (8)$$

引理 3.1 (矩阵元素就是 shared-path 分数). 对任意终端 i, j ,

$$S_{ij}^R := R_{ij} = 2 \sum_{e \in \mathcal{P}(0, \text{LCA}(i, j))} r_e, \quad d_{ij}^R = h_i^R + h_j^R - 2S_{ij}^R = 2 \sum_{e \in \mathcal{P}(i, j)} r_e. \quad (9)$$

因此 RNJ 可直接按 R_{ij} 排序; 距离式只服务于需要加性距离的算法和诊断。

证明. 两条根路径的对称差恰是 i 到 j 的路径。将式 (5) 已给出第一式。将它代入式 (8), 公共边出现系数 $1 + 1 - 2 = 0$, 只属于一条根路径的边出现系数 1, 得到距离式。□

命题 3.2 (RX75 仍是同一拓扑的加性树度量). 令 $s_R, s_X > 0$ 为任意正尺度, $a, b > 0$ 。定义

$$d_{ij} = a \frac{d_{ij}^R}{s_R} + b \frac{d_{ij}^X}{s_X}, \quad h_i = a \frac{R_{ii}}{s_R} + b \frac{X_{ii}}{s_X}. \quad (10)$$

则 d 是原树 T 上的加性度量, 其边长为

$$\omega_e = 2a \frac{r_e}{s_R} + 2b \frac{x_e}{s_X} > 0, \quad (11)$$

相应的 RNJ 直接分数和根深度为

$$S_{ij} := a \frac{R_{ij}}{s_R} + b \frac{X_{ij}}{s_X}, \quad H_i := S_{ii}, \quad d_{ij} = H_i + H_j - 2S_{ij}. \quad (12)$$

因此代码的 $a = 0.75, b = 0.25$ 不改变精确拓扑, 只改变边长。

证明. 把引理 3.1 对 R 和 X 的表达式代入式 (10), 逐边合并系数即可。式 (12) 由 $S^R = R, S^X = X$ 的线性组合直接得到。□

3.2 四点定理与唯一性

定理 3.3 (四点关系). 取四个不同标签 i, j, k, l 。若其诱导四叶树的 *split* 为 $ij | kl$, 连接两侧分叉点的内部路径长度为 $\lambda \geq 0$, 则

$$d_{ij} + d_{kl} =: S_{\text{within}}, \quad (13)$$

$$d_{ik} + d_{jl} = S_{\text{within}} + 2\lambda, \quad (14)$$

$$d_{il} + d_{jk} = S_{\text{within}} + 2\lambda. \quad (15)$$

特别地, 三个 *pair-sum* 中最大的两个相等; 当 $\lambda > 0$ 时, 最小者唯一并确定 *split*。

证明. 将四叶诱导子树分为五段: i, j 侧两条 pendant 路径、 k, l 侧两条 pendant 路径, 以及长度 λ 的中间路径。每个 *pair-sum* 都包含四条 pendant 路径各一次; *cross-sum* 还各自两次经过中间路径, 而 *within-sum* 不经过, 故得到式 (15)。□

定理 3.4 (规范化根向树唯一性). 在假设 2.1 下, 精确的终端距离 d_{ij} 与根深 $h_i = d(0, i)$ 唯一确定根向加权树, 唯一性只差隐藏节点重命名。

证明. 把根 0 作为额外标签, 定义扩充距离 $d(0, i) = h_i, d(0, 0) = 0$ 。它正是原树在标签集 $L \cup \{0\}$ 上的加性度量。由定理 3.3, 每条正长度内部边诱导的 split 都可由某个四元组的唯一最小 pair-sum 识别; 反之全部这类 split 两两兼容, 因为它们来自同一棵树。兼容 split 的包含关系 (等价于 rooted clade 的包含关系) 给出一棵唯一的 Hasse 图: 每个非平凡 clade 对应一个内部节点, 其父节点是严格包含它的最小 clade, 未落入更小 clade 的标签直接接到该节点。该 Hasse 图就是抑制度 2 节点后的根向树。

拓扑确定后, 四点 gap 的一半给出内部边长; 终端根深减去其父节点深度给出 pendant 边长。因此边权也唯一。隐藏节点的整数标签未出现在距离中, 只能确定到重命名。 $\square$

命题 3.5 (不可辨识结构). 仅凭 (d_{ij}, h_i) 无法辨识: (i) 一条边被分成多少条串联的 degree-2 隐藏边; (ii) 零长度内部边两端是否为两个节点; (iii) 没有任何终端后代的设备节点。

证明. 把长度 $a + b$ 的边替换为两条长度 a, b 且中间插入 degree-2 隐藏节点, 任意标签间路径总长不变。对零长度边做收缩同样不改变任何路径长。没有终端后代的枝条不出现在任意根到终端或终端到终端路径上, 也不影响观测距离。故这些结构产生完全相同的数据。 $\square$

4 多场景回归的有限样本误差

4.1 固定设计模型

将全部场景堆叠。记总样本数 $N = \sum_s m_s$, 设计矩阵

$$Z = [P \mid Q \mid G] \in \mathbb{R}^{N \times p}, \quad p = 2n + S, \quad (16)$$

其中 G 为场景示性矩阵; 目标 $Y \in \mathbb{R}^{N \times n}$ 。写成

$$Y = Z\Theta + B + E, \quad \Theta = \begin{bmatrix} R^\top & X^\top & \Gamma^\top \end{bmatrix}^\top. \quad (17)$$

假设 4.1 (回归定理的统计条件). Z 满列秩且在条件于 Z 后, 每个目标列 $E_{\cdot j}$ 满足: 对任意确定向量 a ,

$$\mathbb{E}[\exp(ta^\top E_{\cdot j}) \mid Z] \leq \exp\left(\frac{t^2 \sigma_j^2 \|a\|_2^2}{2}\right). \quad (18)$$

并且 $\|B_{\cdot j}\|_2 \leq \beta_j \sqrt{N}$ 。

该假设允许同一目标列在去均值后出现相关性, 因为去均值矩阵是二范数不超过 1 的线性投影; 但它不允许未校正的 errors-in-variables 偏差。生产数据中的 noisy P/Q 使 Z 与有效残差相关, 因此下述 OLS 定理应理解为“真 P/Q 、工具变量、交叉拟合或 EIV 偏差已单独控制”时的基准定理。

定理 4.2 (OLS entrywise 误差). 令 $\hat{\Theta} = Z^\dagger Y = (Z^\top Z)^{-1} Z^\top Y$ 。对任意 $\delta \in (0, 1)$, 以概率至少 $1 - \delta$,

$$\|\hat{\Theta} - \Theta\|_{\max} \leq \max_j \left\{ \frac{\sigma_j \sqrt{2 \log(2pn/\delta)}}{\sigma_{\min}(Z)} + \frac{\beta_j \sqrt{N}}{\sigma_{\min}(Z)} \right\} =: \eta. \quad (19)$$

证明. 设 $a_k^\top$ 是 $Z^\dagger$ 的第 k 行。则

$$\hat{\Theta}_{kj} - \Theta_{kj} = a_k^\top E_{\cdot j} + a_k^\top B_{\cdot j}, \quad \|a_k\|_2 \leq \|Z^\dagger\|_2 = \frac{1}{\sigma_{\min}(Z)}.$$

由式 (18),

$$\mathbb{P}(|a_k^\top E_{\cdot j}| > t \mid Z) \leq 2 \exp\left(-\frac{t^2 \sigma_{\min}^2(Z)}{2\sigma_j^2}\right).$$

同时 Cauchy-Schwarz 给出 $|a_k^\top B_{\cdot j}| \leq \beta_j \sqrt{N}/\sigma_{\min}(Z)$ 。对 pn 个系数做 union bound, 并令随机项阈值为 $\sigma_j \sqrt{2 \log(2pn/\delta)}/\sigma_{\min}(Z)$, 即得结论。□

推论 4.3 (以设计方差表示的样本阶). 若 $\sigma_{\min}^2(Z) \geq Nv_{\min}$, 则

$$\eta \leq \max_j \left\{ \sigma_j \sqrt{\frac{2 \log(2pn/\delta)}{Nv_{\min}}} + \frac{\beta_j}{\sqrt{v_{\min}}} \right\}. \quad (20)$$

注意分母应是 $v_{\min}$ 。仅由 $\sigma_{\max}^2(Z) \leq Nv_{\max}$ 不能推出旧稿所写的 $\kappa(Z)^2/v_{\max}$ 形式; 若要使用该形式, 还必须另加 $\sigma_{\max}^2(Z) \asymp Nv_{\max}$ 的双边尺度假设。

4.2 ordered 投影链

代码先对称化、截负, 再循环执行 diagonal-order 修正, 最后提升对角线。投影 margin 由输入矩阵的 scale 计算, 因此以下定理先固定一次实际使用的 margin μ 。

定理 4.4 (ordered 基本操作的 max-norm 非扩张性). 设真矩阵 R 对称、非负, 并满足 $R_{ii} - R_{ij} \geq \mu$ 。若 $\|M - R\|_{\max} \leq \eta$, 则代码中的每个基本操作 (对称化、截负、一次 $(2/3, -1/3)$ 半空间修正、最终对角提升) 都保持 $\|M' - R\|_{\max} \leq \eta$ 。故任意有限次 ordered 基本操作的复合仍非扩张。

证明. 对称化后 $|\frac{1}{2}(M_{ij} + M_{ji}) - R_{ij}| \leq \eta$ 。映射 $x \mapsto [x]_+$ 是 1-Lipschitz, 且 $R_{ij} \geq 0$, 故截负不放大误差。

考虑约束 $M_{ii} - M_{ij} \geq \mu$ 的一次违例。令

$$v = \mu - (M_{ii} - M_{ij}) > 0, \quad g = (R_{ii} - R_{ij}) - \mu \geq 0,$$

以及 $e_{ii} = M_{ii} - R_{ii}, e_{ij} = M_{ij} - R_{ij}$ 。则 $v = e_{ij} - e_{ii} - g$, 代码更新

$$M'_{ii} = M_{ii} + \frac{2v}{3}, \quad M'_{ij} = M_{ij} - \frac{v}{3}, \quad M'_{ji} = M_{ij}.$$

于是

$$\begin{aligned} M'_{ii} - R_{ii} &= \frac{1}{3}e_{ii} + \frac{2}{3}e_{ij} - \frac{2}{3}g, \\ M'_{ij} - R_{ij} &= \frac{1}{3}e_{ii} + \frac{2}{3}e_{ij} + \frac{1}{3}g. \end{aligned}$$

第一式的下界也可写成 $e_{ii} + 2v/3 \geq -\eta$, 上界不超过 $(e_{ii} + 2e_{ij})/3 \leq \eta$ 。第二式下界不小于 $(e_{ii} + 2e_{ij})/3 \geq -\eta$; 由 $v > 0$ 得 $g < e_{ij} - e_{ii}$, 故其上界严格小于 $e_{ij} \leq \eta$ 。

最后, 对角提升为 $M'_{ii} = \max\{M_{ii}, \max_{j \neq i} M_{ij} + \mu\}$ 。若触发提升,

$$M'_{ii} \leq \max_{j \neq i} R_{ij} + \eta + \mu \leq R_{ii} + \eta;$$

又 $M'_{ii} \geq M_{ii} \geq R_{ii} - \eta$ 。未触发时显然成立。逐操作复合完成证明。□

说明 4.5 (定理覆盖的代码范围). 当随机 *margin* $\mu(M) = 10^{-6} \text{median}(\text{diag } M)$ 满足 $\mu(M) \leq \min_{i \neq j} (R_{ii} - R_{ij})$ 时, 定理适用。它严格覆盖初始 *lstsq* 后的 *ordered* 投影链。默认的 50 步 *projected-gradient refinement* 会重新计算 *proposal* 的 *scale* 和 *margin*; 其目标值单调下降不等于相对真矩阵的 *max-norm* 单调, 因此不在定理 4.4 的保证内。*tree-covariance* 模式的 *PSD* 特征值投影在 *Frobenius* 范数下有良性性质, 但不保持本文所需的 *entrywise max-norm* 界, 也单独排除。

4.3 随机归一化与 shared-path 误差的正确预算

令 s_R 为 d^R 全部非对角项的均值, $\hat{s}_R$ 为代码中估计距离正项均值。

引理 4.6 (归一化尺度与矩阵误差). 若 $\|\hat{R} - R\|_{\max} \leq \eta_R$ 且 $4\eta_R < d_{\min}^R := \min_{i \neq j} d_{ij}^R$, 则

$$|\hat{s}_R - s_R| \leq 4\eta_R, \quad (21)$$

并且对所有 i, j ,

$$\left| \frac{\hat{R}_{ij}}{\hat{s}_R} - \frac{R_{ij}}{s_R} \right| \leq \frac{\eta_R}{s_R - 4\eta_R} + \frac{4R_{\max}\eta_R}{s_R(s_R - 4\eta_R)} =: \varepsilon_R. \quad (22)$$

其中 $R_{\max} = \max_{ij} R_{ij}$ 。X 有完全相同的结论。

证明. 由距离定义, $|\hat{d}_{ij}^R - d_{ij}^R| \leq |\Delta R_{ii}| + |\Delta R_{jj}| + 2|\Delta R_{ij}| \leq 4\eta_R$ 。条件 $4\eta_R < d_{\min}^R$ 保证全部非对角估计距离为正, 而对角元由构造恒为零, 所以“正项均值”恰好对全部非对角项取均值, 得到式 (21)。再用

$$\left| \frac{\hat{R}_{ij}}{\hat{s}_R} - \frac{R_{ij}}{s_R} \right| \leq \frac{|\hat{R}_{ij} - R_{ij}|}{\hat{s}_R} + \frac{R_{ij}|\hat{s}_R - s_R|}{s_R\hat{s}_R}$$

以及 $\hat{s}_R \geq s_R - 4\eta_R$ 即得。□

推论 4.7 (直接 shared-path 分数的误差). 若 $\hat{R}, \hat{X}$ 对称、非负且 *ordered*, 则代码直接构造

$$\hat{S}_{ij} = 0.75 \frac{\hat{R}_{ij}}{\hat{s}_R} + 0.25 \frac{\hat{X}_{ij}}{\hat{s}_X}. \quad (23)$$

因此

$$\|\hat{S} - S\|_{\max} \leq 0.75\varepsilon_R + 0.25\varepsilon_X =: \varepsilon. \quad (24)$$

证明. 式 (23) 是两个归一化矩阵元素的线性组合; 分别应用引理 4.6 后用三角不等式即得。□

旧稿从 $\hat{d}$ 再定义 $\hat{\rho}$, 随后讨论对角项如何消去; 这只是 $\hat{R}_{ij}$ 的恒等改写。当前代码和证明均直接使用式 (23)。

5 当前 general-tree RNJ 的严格恢复条件

5.1 分叉间隔

对规范化根向树, 将每条“父端为根或隐藏分叉点、子端为隐藏分叉点”的边称为骨架边。定义

$$\lambda_* := \min\{\omega_e : e \text{ 为正长度骨架边}\}. \quad (25)$$

若树没有隐藏分叉点, 则令 $\lambda_* = +\infty$ 。pendant 终端边不进入 λ_* , 因为 RNJ 的 family 判定比较的是不同 LCA 深度, 最小分离来自相邻分叉点之间的骨架边。

引理 5.1 (active frontier 不变量). 在真树上自底向上收缩若干完整 *sibling family* 后, *active* 节点对应两两不相交的真子树; 对任意 *active* 节点 a, b , 其分数 S_{ab} 仍等于 $\text{depth}(\text{LCA}(a, b))$ 。若把一个完整 *family* 收缩到父节点 u , 则对任何外部 *active* 节点 z , 所有 *family* 成员 c 都满足 $S_{cz} = S_{uz}$ 。

证明. 收缩完整子树不会改变该子树外部的根路径。family 成员与外部节点的 LCA 等于其父节点 u 与外部节点的 LCA, 故 shared path 相同。归纳即可。□

定理 5.2 (代码 RNJ 的 ℓ_∞ 安全区间). 设初始 *root depths* 和 *shared paths* 均在真值的 ε 邻域内, 并且代码在每次更新时对 *family-to-outside shared path* 取中位数。若

$$\varepsilon < \frac{\lambda_*}{4}, \quad 2\varepsilon \leq \tau < \lambda_* - 2\varepsilon, \quad (26)$$

则 *rooted_neighbor_joining* 精确恢复规范化根向拓扑; 估计边长可以有误, 但 *rooted clade* 集合完全正确。

证明. 对 while 循环次数归纳。初始时引理 5.1 显然成立, 并假设所有 active depth/shared 值误差不超过 ε 。

取当前最深尚未收缩的真分叉点 u , 深度为 H 。它至少有两个 active 子节点 a, b (非根隐藏节点度数至少 3, 去掉父边后至少有两个子分支), 且 $S_{ab} = H$ 。任何不属于同一个最深 family 的 active 对, 其 LCA 深度至多 $H - \lambda_*$; 即使存在多个同深度 family, 跨 family 的 LCA 仍至少隔一条骨架边。因此

$$\hat{S}_{ab} \geq H - \varepsilon, \quad \hat{S}_{cd} \leq H - \lambda_* + \varepsilon$$

对任意非同-family 对 (c, d) 成立。由 $2\varepsilon < \lambda_*$, 代码选择的全局最大对必属于某个最深真 family。

令选中对为 a, b 。输入分数已裁剪到端点根深度之下, 故代码直接取父深 $\hat{H} = \hat{S}_{ab}$, 从而 $|\hat{H} - H| \leq \varepsilon$ 。

若 c 是同一 family 的另一个 active 子节点, 则 $S_{ac} = S_{bc} = H$, 从而

$$\hat{H} - \min\{\hat{S}_{ac}, \hat{S}_{bc}\} \leq 2\varepsilon \leq \tau,$$

故 c 必被纳入。若 z 在 family 外, 则其真 support 至多 $H - \lambda_*$, 所以

$$\hat{H} - \min\{\hat{S}_{az}, \hat{S}_{bz}\} \geq \lambda_* - 2\varepsilon > \tau,$$

故外部节点不会被误纳入。代码因此恰好收缩一个完整真 family。

对任意剩余节点 z , family 每个成员与 z 的真 shared path 都等于 S_{uz} (引理 5.1)。每个估计值在其 ε 邻域内, 故中位数也在同一邻域内。clip 到 $[0, \min(\hat{H}_u, \hat{H}_z)]$ 不会把误差扩大超过 ε : 真值属于真区间, 估计区间端点与真端点相差至多 ε 。于是归纳不变量保持。

当 active 节点全是根的直接子分支时, 所有真 pair support 为 0, 估计值经非负 clip 位于 $[0, \varepsilon]$, 而 $\tau \geq 2\varepsilon$, 代码正确停止并把它们接到给定根。在此之前若仍有非根 family, 则最大真 parent depth 至少为 λ_* , 其估计值至少 $\lambda_* - \varepsilon > \tau$, 不会提前停止。故全部收缩顺序均与真树兼容, 最终 rooted clade 集合精确。□

说明 5.3 (默认 0.16 容差的地位). 代码取 $\tau = 0.16 \text{median}(\hat{H})$ 。定理只说明: 若这个数据依赖值恰好落入式 (26), 则恢复有保证。固定比例本身不能保证对新谱线满足该区间; 更合理的理论参数应由 *shared-path* 不确定度上界 ε 与最小可分辨骨架边下界共同确定。

6 quartet clade 证据的正确公式与鲁棒半径

对候选 clade C , 取 $i, j \in C$ 和 $k, l \notin C$; 代码把已知根作为 complement 中的额外 anchor。定义

$$G_{ij|kl}(d) := \min\{d_{ik} + d_{jl}, d_{il} + d_{jk}\} - (d_{ij} + d_{kl}). \quad (27)$$

命题 6.1 (split gap 与确定性扰动界). 若真四叶 *split* 为 $ij | kl$, 内部路径长度为 λ , 则 $G_{ij|kl}(d) = 2\lambda$ 。若 $\|\hat{d} - d\|_{\max} \leq \xi$, 则

$$|G_{ij|kl}(\hat{d}) - 2\lambda| \leq 4\xi. \quad (28)$$

特别地, $\xi < \lambda/2$ 时 *gap* 保持为正。

证明. 第一式是定理 3.3. 每个 pair-sum 含两个距离项, 误差至多 2ξ ; 两个数的 minimum 映射在 max-norm 下是 1-Lipschitz, 故 cross-min 误差至多 2ξ , within-sum 误差至多 2ξ , 相减得到 4ξ . $\square$

旧稿使用“一个 cross-sum 减三个和的 max”。在真 split 下两个 cross-sum 相等, 该量等于零, 不能作为正 gap。式 (27) 与 `quartet_gaps_for_clade` 的实际实现一致。

命题 6.2 (bootstrap 正支持率只估计扰动稳定性). 固定原始数据 D 与扰动/块采样机制。令一次 *replicate* 的接受指示量为 $I_b \in \{0, 1\}$, 条件成功率 $p_D = \mathbb{P}(I_b = 1 | D)$ 。若 *replicates* 条件独立, 则

$$\mathbb{P}\left(\left|\frac{1}{B} \sum_{b=1}^B I_b - p_D\right| > u \mid D\right) \leq 2e^{-2Bu^2}. \quad (29)$$

证明. 条件于 D 后, I_b 是独立 Bernoulli 变量, 直接应用 Hoeffding 不等式。 $\square$

式 (29) 只控制 Monte Carlo 误差; p_D 是“在选定扰动机制下算法重复接受”的概率, 不是 $\mathbb{P}(C \text{ 为真} | D)$ 。固定模型偏差可使错误 clade 具有很高 p_D 。

7 一层 clade 聚合的精确恒等式

7.1 外部等价

定义 7.1 (完整悬挂 clade). 若隐藏节点 g 的全部终端后代恰为 C , 则称 C 是以 g 为边界的完整悬挂 *clade*。记 R_{gj} 为把 g 当作一行标签时的共享路径灵敏度, R_{gg} 为根到 g 的两倍电阻深度; X 同理。

引理 7.2 (外部行等价). 若 C 是以 g 为边界的完整悬挂 *clade*, 则

$$R_{ij} = R_{gj}, \quad X_{ij} = X_{gj}, \quad i \in C, j \notin C, \quad (30)$$

$$R_{gj} = R_{gg}, \quad X_{gj} = X_{gg}, \quad j \in C. \quad (31)$$

证明. 对 $i \in C, j \notin C$, i 的根路径在 g 以下的部分不可能与 j 的根路径相交, 故 $\mathcal{P}(0, i) \cap \mathcal{P}(0, j) = \mathcal{P}(0, g) \cap \mathcal{P}(0, j)$, 得到式 (30)。对 $j \in C$, g 位于 j 的根路径上, 二者公共根路径正是 $\mathcal{P}(0, g)$, 得到式 (31)。 $\square$

7.2 pseudo 功率与边界电压

定理 7.3 (oracle clade 收缩精确性). 在定理 2.2 的线性无损模型下, 令

$$p_g = \sum_{j \in C} p_j, \quad q_{quad} q_g = \sum_{j \in C} q_j. \quad (32)$$

对 $i \in C$ 定义

$$\tilde{w}_{g,i} := w_i + \sum_{j \in C} (R_{ij} - R_{gj}) p_j + \sum_{j \in C} (X_{ij} - X_{gj}) q_j. \quad (33)$$

则:

- (a) 对 $j \in C$, $R_{ij} - R_{gj} \geq 0, X_{ij} - X_{gj} \geq 0$, 故代码中的正部截断在真值处不激活;
- (b) 对任意 $i \in C$, $\tilde{w}_{g,i} = w_g$, 与 i 无关;
- (c) 把 C 子树替换为 *pseudo* 终端 g 后, 其余终端与 g 的平方电压方程仍精确属于同一类 *reduced model*, 且 C 内注入只通过 (p_g, q_g) 出现。

证明. 若 $i, j \in C$, 二者公共路径包含 $\mathcal{P}(0, g)$, 所以

$$R_{ij} - R_{gj} = 2 \sum_{e \in [\mathcal{P}(0, i) \cap \mathcal{P}(0, j)] \setminus \mathcal{P}(0, g)} r_e \geq 0,$$

X 同理, 证明 (a)。

由平方电压模型,

$$w_g - w_i = \sum_{j \in L} (R_{ij} - R_{gj}) p_j + \sum_{j \in L} (X_{ij} - X_{gj}) q_j.$$

对 $j \notin C$, 引理 7.2 使差值为零, 故求和可限制在 C , 右端正是式 (33) 的修正项。这证明 $\tilde{w}_{g,i} = w_g$ 。

对任意外部终端 $a \notin C$,

$$\sum_{j \in C} R_{aj} p_j = R_{ag} \sum_{j \in C} p_j = R_{ag} p_g$$

由外部等价成立; 对边界行, $\sum_{j \in C} R_{gj} p_j = R_{gg} p_g$ 。 X, q 同理。因此收缩后的每一行都与把 g 当作单个终端的 *reduced model* 完全一致, 证明 (c)。 $\square$

推论 7.4 (边界深度的最小 off-diagonal 公式). 若 g 在 C 内至少有两个含终端的子分支, 则

$$R_{gg} = \min_{i \neq j, i, j \in C} R_{ij}, \quad X_{gg} = \min_{i \neq j, i, j \in C} X_{ij}. \quad (34)$$

证明. 任意 $i, j \in C$ 的公共根路径包含根到 g 的路径, 故 $R_{ij} \geq R_{gg}$ 。分别从 g 的两个不同子分支选 i, j , 其 g 以下公共路径为空, 等号成立。 $\square$

代码用 off-diagonal 的 0.2 分位数而非 minimum, 并对子节点去嵌入结果取 median、再与原始均值按 0.5 混合。它们在无噪 oracle 极限都以 w_g 为不动点, 但有限噪声下是鲁棒启发式, 不由定理 7.3 自动获得最优性。

7.3 含量测误差时的精确传播式

旧稿声称对 $|C| = k$ 个子节点平均必将噪声方差从 σ^2 降到 σ^2/k 。这在 noisy P/Q 和公共根电压存在时不成立。下面给出正确公式。

令测得的平方电压为 $w_i^m = w_i + \xi_i$ ，测得的注入为 $p_j^m = p_j + u_j, q_j^m = q_j + z_j$ 。设 oracle 差分矩阵 $\Delta R_{ij} = R_{ij} - R_{gj}$ 、 $\Delta X_{ij} = X_{ij} - X_{gj}$ ，且仅取 $j \in C$ 。对任意权重 a_i 满足 $\sum_{i \in C} a_i = 1$ ，定义线性去嵌入平均。其误差为

$$\varepsilon_g = \sum_{i \in C} a_i \xi_i + \sum_{j \in C} \left(\sum_{i \in C} a_i \Delta R_{ij} \right) u_j + \sum_{j \in C} \left(\sum_{i \in C} a_i \Delta X_{ij} \right) z_j. \quad (35)$$

命题 7.5 (pseudo 噪声协方差). 若 ξ, u, z 相互独立、均值为零，协方差分别为 $\Sigma_\xi, \Sigma_p, \Sigma_q$ ，令 $\Delta R_C, \Delta X_C \in \mathbb{R}^{k \times k}$ ，则

$$\text{Var}(\varepsilon_g) = a^\top \Sigma_\xi a + a^\top \Delta R_C \Sigma_p \Delta R_C^\top a + a^\top \Delta X_C \Sigma_q \Delta X_C^\top a. \quad (36)$$

同时 *pseudo* 注入误差满足

$$\text{Var}(p_g^m - p_g) = \mathbf{1}^\top \Sigma_p \mathbf{1}, \quad \text{Var}(q_g^m - q_g) = \mathbf{1}^\top \Sigma_q \mathbf{1}. \quad (37)$$

证明. 式 (35) 可写为 $a^\top \xi + a^\top \Delta R_C u + a^\top \Delta X_C z$ 。独立随机向量的方差可加，得到式 (36)。注入聚合误差是 $\mathbf{1}^\top u$ 和 $\mathbf{1}^\top z$ ，直接得到式 (37)。□

只有在 $\Delta R_C u, \Delta X_C z$ 可忽略、 $\Sigma_\xi = \sigma^2 I$ 、 $a = \mathbf{1}/k$ 时，第一项才等于 σ^2/k 。若有公共平方电压误差 $\Sigma_\xi = \sigma_{\text{ind}}^2 I + \sigma_{\text{com}}^2 \mathbf{1}\mathbf{1}^\top$ ，则

$$a^\top \Sigma_\xi a = \frac{\sigma_{\text{ind}}^2}{k} + \sigma_{\text{com}}^2,$$

共模项完全不衰减。iid P/Q 噪声反而使 pseudo 注入绝对方差按 k 增长。因此生产管线是否获得更高信噪比取决于负荷信号如何随 k 增长、EIV 权重、服务线差分 and 共模误差，不能只由终端数量断言。

8 两阶段恢复：正确的条件定理与样本复杂度

8.1 clade 集合的分解

设 $C_1, \dots, C_K$ 是两两不相交的真完整 clade。收缩后 backbone 终端为 K 个 pseudo 节点加未聚合 singleton，数量

$$n_B = n - \sum_{c=1}^K (|C_c| - 1). \quad (38)$$

真 rooted clade 集合可唯一分解为：每个 C_c 内部的局部 clades、 C_c 本身，以及 backbone clade 展开 pseudo 标签后得到的 unions。

定理 8.1 (两阶段组合正确性). 设检测器给出的 $C_1, \dots, C_K$ 全是真完整 clade；oracle 聚合满足定理 7.3。若 backbone 与每个 local stage 的 shared-path 误差分别为 $\varepsilon_B, \varepsilon_c$ ，其骨架 margin 为 λ_B, λ_c ，并选择

$$2\varepsilon_q \leq \tau_q < \lambda_q - 2\varepsilon_q, \quad q \in \{B, 1, \dots, K\}, \quad (39)$$

则 backbone RNJ、全部 local RNJ 和 clade 展开合并精确恢复完整规范化根向树。

证明. 定理 5.2 分别保证 backbone 与各 local tree 的 rooted clades 精确。backbone 中每个 pseudo 标签 g_c 代表终端集合 C_c ；将 backbone clade 中的 g_c 替换为 C_c ，恰得到真树中跨越 clade 边界的所有 clades。每个 local RNJ 给出严格包含于 C_c 的所有 clades，再加入 C_c 本身。根据前述 clade 集合分解，三类集合无遗漏、无额外项。定理 3.4 说明该 clade 集合唯一对应真规范化根向树。□

8.2 stagewise 有限样本界

对 stage q ，记 n_q 为终端数， $p_q = 2n_q + S$ ，设计最小方差为 v_q ，响应噪声次高斯参数上界为 σ_q ，模型偏差上界为 β_q 。令 C_q 是从 $\|\hat{\Theta}_q - \Theta_q\|_{\max}$ 到归一化 shared-path 误差的常数；R-only 且无随机归一化时 $C_q = 1$ ，RX75 时由引理 4.6 给出局部常数。

推论 8.2 (完整两阶段样本复杂度). 给每个 stage 分配失败概率 δ_q ，另给 clade 检测事件分配 δ_C 。若

$$a_q := \frac{\lambda_q}{4C_q} - \frac{\beta_q}{\sqrt{v_q}} > 0 \quad (40)$$

且

$$N \geq \max_{q \in \{B, 1, \dots, K\}} \frac{2\sigma_q^2}{v_q a_q^2} \log \frac{2p_q n_q}{\delta_q}, \quad (41)$$

同时各 τ_q 按式 (39) 选取，则完整恢复概率至少 $1 - \delta_C - \sum_q \delta_q$ 。

证明. 由推论 4.3，stage q 的系数误差不超过

$$\eta_q \leq \sigma_q \sqrt{\frac{2 \log(2p_q n_q / \delta_q)}{N v_q}} + \frac{\beta_q}{\sqrt{v_q}}.$$

式 (41) 等价于 $\eta_q \leq \lambda_q / (4C_q)$ ，因此 shared-path 误差 $\varepsilon_q \leq C_q \eta_q < \lambda_q / 4$ ，RNJ 安全区间非空。对所有 stage 和 clade 检测事件做 union bound，再应用定理 8.1。□

推论 8.3 (何时才有 backbone 的 $|C|$ 倍收益). 进一步假设 backbone 的每个 pseudo 响应都是至少 k 个独立同方差响应的 oracle 均值；没有 P/Q EIV、共模误差或边界行估计误差；聚合前后 $v_B, C_B, \lambda_B, \beta_B$ 不变。则 $\sigma_B^2 \leq \sigma^2 / k$ ，式 (41) 中 backbone 项最多按 k 倍下降。

这不是完整管线样本量必降 k 倍：local stage 的最大项仍可能主导；未聚合 singleton 的响应噪声不下降；式 (36) 中的 EIV/共模项也可能主导。此外设计维数从 $2n + S$ 降到 $2n_B + S$ 是严格事实，但条件数没有普适单调性。例如原始正交列 e_1, e_2, e_3 条件数为 1，把前两列求和后 $[e_1 + e_2, e_3]$ 的条件数为 $\sqrt{2}$ ，反而变差。生产代码重新报告聚合设计的条件数是必要审计，而非冗余诊断。

9 固定候选树上的参数重估

9.1 树参数化

给定 rooted candidate T ，令 A_T 为其路径矩阵。任何非负支路参数都产生

$$R_T = 2A_T \text{diag}(r)A_T^\top, \text{quad}X_T = 2A_T \text{diag}(x)A_T^\top, \text{quad}r, x \geq 0. \quad (42)$$

命题 9.1 (已知最小拓扑上的参数可辨识性). 若 T 满足假设 2.1，则映射 $r \mapsto A_T \text{diag}(r)A_T^\top$ 是单射； x 同理。

证明. 矩阵对角给出每个终端深度; 对任意隐藏节点 u , 从其两个不同子分支各取一个终端 i, j , 则 $R_{ij}/2$ 等于 u 的根深。于是所有隐藏节点和终端的根深都由 R 唯一确定。每条边长度等于子节点深度减父节点深度, 因此所有 r_e 唯一。若两个参数向量产生同一矩阵, 它们逐边相同, 故映射单射。 $\square$

9.2 固定权重 NNLS 与 IRLS 边界

把式 (42) 代入线性电压模型。对样本 t ,

$$R_T p_t = 2 \sum_e r_e a_e (a_e^\top p_t),$$

其中 a_e 是 A_T 的第 e 列。将全部样本堆叠, 得到对 (r, x) 线性的设计 H_T 。权重固定时, 代码子问题是

$$\min_{r, x \geq 0} \|W^{1/2}(y - H_T[r^\top, x^\top]^\top)\|_2^2 + \lambda \|(r, x)\|_2^2. \quad (43)$$

命题 9.2 (固定权重子问题). 式 (43) 是凸优化; 若 $\lambda > 0$, 或 $W^{1/2}H_T$ 满列秩, 则目标严格凸, 解唯一。

证明. Hessian 为 $2H_T^\top W H_T + 2\lambda I \succeq 0$, 非负正交象限是凸集。在给定条件下 Hessian 正定, 故严格凸并有唯一极小点。 $\square$

生产 structured-EIV 令权重随 (r, x) 变化并交替更新, 因此完整 IRLS 目标通常非凸; 上面只保证每个固定权重 NNLS 子问题的全局解, 不保证交替序列达到全局最优。

10 GTLS、EIV predictive likelihood 与有限候选后验

10.1 可分离 GTLS 的 SVD 推导

去均值后写 $Y \simeq ZB$, 按列噪声尺度白化: $Z_w = ZS_Z^{-1}, Y_w = YS_Y^{-1}, W = [Z_w, Y_w]$ 。

命题 10.1 (理想 multiresponse TLS 解). 考虑最小 Frobenius 扰动使 $[Z_w + \Delta Z_w, Y_w + \Delta Y_w]$ 的秩至多 p 。令 W 最小的 n 个右奇异向量组成

$$V_2 = \begin{bmatrix} V_{Z2} \\ V_{Y2} \end{bmatrix}.$$

若 V_{Y2} 可逆, 则

$$\hat{B}_w = -V_{Z2}V_{Y2}^{-1}, \quad \hat{B} = S_Y^{-1}\hat{B}_wS_Y. \quad (44)$$

证明. Eckart–Young 定理说明, 删除最小的 n 个奇异分量给出到秩 p 矩阵集合的最近点。该修正矩阵的右零空间由 V_2 张成。回归约束等价于

$$[Z_w + \Delta Z_w, Y_w + \Delta Y_w] \begin{bmatrix} \hat{B}_w \\ -I \end{bmatrix} = 0.$$

因此存在可逆矩阵 C 使 $[\hat{B}_w^\top, -I]^\top = V_2 C$ 。下块给出 $-I = V_{Y2} C$, 故 $C = -V_{Y2}^{-1}$, 上块得到式 (44)。反白化完成证明。 $\square$

使用 pseudoinverse、相对噪声随样本变化、AC 模型失配、0.99 OLS shrinkage 和后续树约束时, 已经超出命题 10.1; 这些步骤的作用是候选多样化, 不应声称为精确 GTLS MLE。

10.2 EIV predictive variance

若正确候选下的预测残差近似为

$$e_{ti} = \nu_{ti} - \sum_j R_{ij} u_{tj}^P - \sum_j X_{ij} u_{tj}^Q + m_{ti},$$

各项独立、均值为零，则

$$s_{ti}^2 = \sigma_{v^2,ti}^2 + \sum_j R_{ij}^2 \sigma_{P,tj}^2 + \sum_j X_{ij}^2 \sigma_{Q,tj}^2 + \sigma_{m,i}^2. \quad (45)$$

高斯近似的逐点负对数似然（忽略公共常数）为

$$\ell_{ti} = \frac{1}{2} \left(\log s_{ti}^2 + \frac{e_{ti}^2}{s_{ti}^2} \right). \quad (46)$$

式 (45) 由独立线性组合的方差相加得到；若误差相关，必须加入完整协方差的交叉项。

10.3 有限候选 generalized posterior

对有限候选池 $\mathcal{K}$ ，定义每棵树的留出分数 L_T 。代码形式为

$$\pi(T | D) = \frac{\exp[-N_{\text{eff}}(L_T - L_{\min})/\tau]}{\sum_{U \in \mathcal{K}} \exp[-N_{\text{eff}}(L_U - L_{\min})/\tau]}. \quad (47)$$

减去 $L_{\min}$ 只改善数值稳定性，不改变概率。

命题 10.2 (归一化、MAP 与 clade marginal). 式 (47) 在有限 $\mathcal{K}$ 上严格归一化，MAP 候选等于 $\arg \min_T L_T$ 。任意 clade C 的 marginal 为

$$\pi(C | D) = \sum_{T \in \mathcal{K}} \pi(T | D) \mathbf{1}\{C \in \mathcal{C}(T)\}. \quad (48)$$

证明. 分母是全部正权重之和，故概率和为 1；指数函数严格单调，最大权重对应最小分数。clade marginal 是对事件 $\{T : C \in \mathcal{C}(T)\}$ 的有限求和。□

定理 10.3 (有限候选留出排序的一致性). 设真树 $T_0 \in \mathcal{K}$ ，训练后参数固定；留出数据由 M 个独立块组成，块损失 $\ell_b(T)$ 为一致可积且次指数。若对所有 $T \neq T_0$,

$$\mathbb{E}[\ell_b(T) - \ell_b(T_0)] \geq \Delta_T > 0, \quad (49)$$

且复杂度惩罚为 $o(1)$ ，则经验分数的 MAP 选择以概率趋于 1 选中 T_0 ，并且固定 $\tau > 0$ 时 $\pi(T_0 | D) \rightarrow 1$ 。

证明. 对每个 $T \neq T_0$ ，次指数 Bernstein 不等式给出

$$\mathbb{P}\left(\frac{1}{M} \sum_b [\ell_b(T) - \ell_b(T_0)] \leq 0\right) \leq 2 \exp[-cM \min(\Delta_T^2/K_T^2, \Delta_T/K_T)]$$

对某个尺度常数 K_T 与绝对常数 $c > 0$ 成立。对有限候选做 union bound，误选概率趋于零。事件上每个经验 gap 收敛到正数，式 (47) 中错误候选相对真树的权重比按 $\exp[-M\Delta_T/\tau]$ 衰减，故真树质量趋于 1。□

该定理解释了独立留出的价值，但有两个不可绕过的前提：真树必须在候选池内，且真树在所用 predictive loss 下具有正风险 gap。AC ranker 不能创造缺失候选；模型错设时，后验集中到的是候选池中的 pseudo-true minimizer，而不必是真物理树。

11 现有主线的端到端条件定理

定理 11.1 (端到端条件正确性). 若同时满足:

- (A1) 网络满足假设 2.1, 且线性模型偏差受控;
- (A2) OLS/EIV 估计在每个 $stage$ 满足推论 8.2 的误差界;
- (A3) $ordered$ 投影使用的 $margin$ 与真矩阵兼容, 且不调用未覆盖的 $refinement/PSD$ 步骤, 或另行证明这些步骤不破坏误差界;
- (A4) RNJ 的实际 τ_q 落在式 (39);
- (A5) 被聚合的 $clades$ 全真, $oracle$ 边界行/电压误差满足 $stagewise$ 界;
- (A6) 候选池包含真树, 固定树拟合识别充分, 留出 $predictive risk$ 对真树有正 gap ;

则端到端 MAP 输出以推论 8.2 与定理 10.3 给出的概率精确恢复规范化 $rooted clade$ 集合。

证明. (A1)–(A4) 与定理 5.2 保证基础和 $stagewise RNJ$ 候选的结构正确; (A5) 与定理 8.1 保证聚合/展开候选正确; (A6) 与定理 10.3 保证留出排序最终选择真候选。各失败事件用 union bound 合并即可。□

定理 11.1 是“若每个模块的可检验条件成立, 则组合正确”的闭环证明, 不是对当前默认配置的无条件背书。当前配置中至少有下列未闭环项:

1. noisy P/Q 造成 EIV 与 OLS 有效残差相关;
2. 默认 50 步 projected-gradient refinement 不受 max-norm 定理覆盖;
3. $\tau = 0.16 \text{ median}(h)$ 未由 ε, λ_* 校准;
4. $NJ/RG/bootstrap$ /四源门控相关, 不能把支持度相乘为独立概率;
5. boundary quantile、median 和 0.5 shrinkage 尚无有限样本最优性;
6. structured- EIV IRLS 与一次 AC correction 只有局部/单调改进, 不保证全局最优;
7. representative held-out scenarios 不是严格 iid blocks;
8. hidden injection、三相不平衡、调压器、不同步/区间平均量测尚未进入观测模型。

12 代码对应与可执行审计清单

数学对象	当前实现
式 (4) 的真 R/X	<code>terminal_case33/models/lin_distflow.py</code>
AC 数据生成与式 (2)	<code>terminal_case33/models/ac_powerflow.py</code>
式 (17) 的多场景拟合	<code>terminal_case33/estimation/multiscenario.py</code>

定理 4.4 的 ordered 操作	<code>terminal_case33/estimation/matrix_constraints.py</code>
RX75 直接分数、根深与式 (23)	<code>terminal_case33/graph/sensitivity_geometry.py</code>
定理 5.2 的 general-tree RNJ	<code>terminal_case33/graph/rooted_neighbor_joining.py</code>
式 (27)	<code>terminal_case33/graph/quartet_significance.py</code>
定理 7.3 与 pseudo 场景	<code>terminal_case33/graph/rooted_hierarchy.py</code>
候选门控与软收缩 beam	<code>terminal_case33/pipeline/peripheral_edge_proposals.py</code> 、 <code>unified_topology_pipeline.py</code>
固定树 EIV/AC 排序	<code>terminal_case33/pipeline/ac_likelihood.py</code>
有限候选 posterior	<code>terminal_case33/pipeline/gtls_topology_posterior.py</code>

复现实验或论文写作时，至少应同时导出： $\sigma_{\min}(Z)$ 或条件数、估计 shared-path bootstrap 误差、最小 family separation、实际 RNJ τ 、candidate-oracle recall、每个聚合 clade 的 quartet gap、pseudo 电压误差分解、固定树参数秩与留出 loss gap。只有这些量能判断端到端定理的条件是否接近成立。

13 结论

当前方法最坚实的数学核心是

径向零注入树 $\implies R/X$ 共享路径矩阵 $\implies$ 同拓扑加性距离 $\implies$ 规范化隐藏树唯一性。

在有限样本下，正确链条应写成

回归误差界 $\implies$ 归一化 shared-path 误差 $\varepsilon \implies 2\varepsilon \leq \tau < \lambda_* - 2\varepsilon \implies$ RNJ 精确恢复。

真 clade 的 oracle 收缩在模型内严格精确，但“平均 k 个终端”不自动等于“总体样本复杂度降低 k 倍”。正确的两阶段结论必须使用 backbone 与所有 local stage 的最大样本需求，并显式传播 noisy P/Q 、共模电压和边界行误差。固定树 EIV/AC 层的价值是物理重估与留出排序；它不能弥补候选覆盖缺失，也不能把 generalized posterior 自动解释为校准的真实后验概率。

这组结论给出了一个可投稿的理论框架，也给出了下一步研究的明确方向：把默认容差改成不确定度校准量、为 pseudo 边界建立完整 EIV 协方差、用候选覆盖定理连接 quartet 局部编辑与 AC 风险，以及为非线性 AC/三相模型建立可验证的局部可辨识条件。

参考文献

- [1] P. Buneman, The recovery of trees from measures of dissimilarity, 1971.
- [2] N. Saitou and M. Nei, The neighbor-joining method, *Molecular Biology and Evolution*, 1987.
- [3] K. Atteson, The performance of neighbor-joining methods of phylogenetic reconstruction, *Algorithmica*, 1999.
- [4] J. Ni and S. Tatikonda, Network tomography based on additive metrics, *IEEE Transactions on Information Theory*, 2011.

- [5] M. J. Choi, V. Y. F. Tan, A. Anandkumar, and A. S. Willsky, Learning latent tree graphical models, *JMLR*, 2011.
- [6] D. Deka, S. Backhaus, and M. Chertkov, Learning topology of distribution grids using only terminal node measurements, 2016.