

由终端阻抗距离矩阵恢复隐藏树拓扑：Neighbor Joining、误差鲁棒性与可恢复性证明

terminal_load_only_case33 notes

2026 年 7 月 10 日

1 问题设定

设配电网为一棵径向树 $T = (V, E)$ ，根节点 0 可观测，终端/用户节点集合为 $L = \{1, \dots, n\}$ 。内部节点 $H = V \setminus (L \cup \{0\})$ 为隐藏零注入节点。在终端节点上估计得到 reduced sensitivity matrix R 后，可构造终端间阻抗距离

$$d_R(i, j) = R_{ii} + R_{jj} - 2R_{ij}, \quad i, j \in L. \quad (1)$$

若 R_{ij} 等于 i, j 从根出发公共路径电阻和，则

$$d_R(i, j) = \sum_{e \in \text{path}(i, j)} r_e, \quad (2)$$

即 d_R 是由隐藏树边权诱导的 additive tree metric。类似地， X 可给出电抗距离 d_X 。本说明只写 d ，可理解为 d_R 、 d_X 或二者的加权组合。

需要特别区分三类拓扑对象：

- **terminal MST**: 只在 L 上选边，不显式生成隐藏节点；
- **pseudo cluster tree**: 先把高置信终端边收缩成 pseudo node，再在 pseudo 层辨识；
- **latent tree reconstruction**: 仅根据 $d(i, j)$, $i, j \in L$ ，显式生成隐藏节点和边权。

当前代码中真正会从距离矩阵生成 latent hidden node 的入口是

```
terminal_case33/graph/latent_tree_baselines.py::neighbor_joining_baseline.
```

它用负整数 $-1, -2, \dots$ 标记算法生成的隐藏节点。

2 Neighbor Joining 算法

Neighbor Joining (NJ) 是 Saitou 和 Nei 提出的经典距离树重构算法。它输入观测叶节点之间的距离矩阵，输出一棵无根加权树。算法本质上是 bottom-up 的：每一步从当前 active 节点中选择一对最像 sibling 的节点，将其合并到一个新生成的 latent node。

2.1 符号

令当前 active 节点集合为 A , $|A| = m$ 。当前距离为 $d(a, b)$ 。定义每个节点的 row sum:

$$S_a = \sum_{k \in A, k \neq a} d(a, k). \quad (3)$$

NJ 对每对 $a \neq b$ 计算

$$Q(a, b) = (m - 2)d(a, b) - S_a - S_b. \quad (4)$$

选择 $Q(a, b)$ 最小的一对 (a, b) , 创建新的 latent node u , 并连接

$$u - a, \quad u - b.$$

两条新边的长度估计为

$$\ell(a, u) = \frac{1}{2}d(a, b) + \frac{S_a - S_b}{2(m - 2)}, \quad (5)$$

$$\ell(b, u) = d(a, b) - \ell(a, u). \quad (6)$$

随后删除 a, b , 加入 u , 并更新 u 到任意其他 active 节点 k 的距离:

$$d(u, k) = \frac{1}{2} [d(a, k) + d(b, k) - d(a, b)]. \quad (7)$$

重复直到只剩两个 active 节点, 最后连接它们。

2.2 代码对应

当前实现位于

`terminal_case33/graph/latent_tree_baselines.py`.

主要步骤对应如下:

- active 节点集合: `active = list(labels)`;
- $Q(a, b)$ 选择: 实现中按式 (4) 构造 key, 对所有 active pair 取最小值;
- 新隐藏节点: `latent = next_latent`, 从 -1 开始递减;
- 新边长度: `left_length` 和 `right_length`;
- 距离更新: `0.5 * (get(left, node) + get(right, node) - separation)`。

当前实现为了避免数值病态, 会将负边长截断为 0:

$$\hat{\ell} \leftarrow \max(\hat{\ell}, 0). \quad (8)$$

这只是数值保护, 不是严格统计修正。若距离误差较大, NJ 仍可能选错 sibling。

3 一个小例子

假设四个终端 A, B, C, D 来自如下隐藏树：

$$\begin{array}{ccccccc} A & - & H_1 & - & H_0 & - & H_2 & - & C \\ & & | & & & & | & & \\ & & B & & & & D & & \end{array}$$

设 $A - H_1, B - H_1, C - H_2, D - H_2$ 的长度均为 1, $H_1 - H_0$ 和 $H_0 - H_2$ 的长度均为 2。则终端距离为

$$d(A, B) = 2, \quad d(C, D) = 2, \quad d(A, C) = d(A, D) = d(B, C) = d(B, D) = 6.$$

对四个 active 节点, 有

$$S_A = S_B = S_C = S_D = 14.$$

于是

$$Q(A, B) = 2 \cdot 2 - 14 - 14 = -24,$$

而

$$Q(A, C) = 2 \cdot 6 - 14 - 14 = -16.$$

因此 NJ 会优先合并 A, B , 生成隐藏节点 H_1 的估计节点 -1 。同理后续会合并 C, D , 生成 -2 , 最后连接 -1 与 -2 。这就是从终端距离矩阵显式生成隐藏拓扑。

4 现有文献如何处理隐藏拓扑恢复

4.1 系统发育/距离树文献

Saitou-Nei 的 NJ 是最常用的距离矩阵到无根树的构造方法之一。它不假设 ultrametric, 因此不同叶节点到根的距离可以不相同, 这比 UPGMA 更适合一般加权树。NJ 的理论基础后来被解释为一种对 balanced minimum evolution 目标的贪心近似。

Atteson 给出了经典鲁棒性条件: 若估计距离矩阵 $\hat{d}$ 与真实 additive distance d 满足

$$\|\hat{d} - d\|_\infty < \frac{1}{2}\ell_{\min}, \quad (9)$$

其中 $\ell_{\min}$ 是真实树中最短边长, 则 NJ 可恢复正确拓扑。Mihaescu-Levy-Pachter 进一步从 quartet 角度解释 NJ 为什么在一些不满足式 (9) 的情况下仍然成功。

这类结论对配电网有直接启发: 如果由电压/功率数据估计出的阻抗距离误差小于最短可辨识边的 margin, 隐藏树拓扑可以被稳定恢复; 若误差与短支路阻抗同阶, 任何纯距离树算法都会变得不稳定。

4.2 Latent tree graphical model 文献

Choi-Tan-Anandkumar-Willsky 研究了 latent tree graphical models, 在只有部分节点可观测时, 利用 information distance 恢复 minimal latent tree。他们提出 Recursive Grouping 和

CLGrouping: 前者局部识别 sibling 与 parent-child 关系, 后者先构造 observed-node 预树, 再在局部子集上递归恢复隐藏节点。

Anandkumar 等人的 spectral recursive grouping 进一步给出了有限样本恢复条件: 只要二阶统计量估计误差足够小, 且树边长度、节点度数等满足可分性条件, 就能以高概率恢复结构。

对当前配电网问题来说, d_R, d_X 扮演了 information distance 的角色。区别是: 我们的距离来自物理灵敏度矩阵, 误差来自 AC 潮流非线性、量测噪声、根电压公共模态、P/Q 激励病态和滤波偏差。

4.3 配电网拓扑辨识文献

Deka-Backhaus-Chertkov 和 Park-Deka-Chertkov 的 minimal observability 工作强调: 即使只在 terminal/end-user 节点量测, 也可以利用径向网的电压关系恢复隐藏内部节点和线路参数。这类方法通常不直接套用 NJ, 而是利用三元组、路径公共部分、父子关系判别或电压方差趋势来构造隐藏树。

Deka-Kekatos-Cavaro 的教程总结了配电网拓扑学习中常见路径: 距离/相关性图学习、物理约束最小二乘、有限量测下的可辨识性、以及主动扰动下的 voltage response 方法。它也说明了 meter placement、隐藏节点相邻性、注入统计独立性和潮流模型误差会显著影响可恢复性。

5 为什么准确距离矩阵可恢复隐藏拓扑

定义 1 (Additive tree metric). 给定一棵加权树 $T = (V, E, w)$ 和叶节点集合 L 。若对任意 $i, j \in L$,

$$d(i, j) = \sum_{e \in \text{path}_T(i, j)} w_e, \quad (10)$$

则称 d 是由 T 诱导的 *additive tree metric*。

假设 1 (最小隐藏树). 所有边权 $w_e > 0$, 且除根以外的隐藏内部节点度数至少为 3。度数为 2 的隐藏链已被压缩为一条等效边。

说明 1. 该假设是必要的。若隐藏节点度数为 2, 例如 $a - h_1 - h_2 - b$, 仅凭叶间距离只能识别总长度 $w(a, h_1) + w(h_1, h_2) + w(h_2, b)$, 无法唯一知道中间有几个度数为 2 的隐藏节点。

定理 1 (Additive distance 的拓扑唯一性). 在最小隐藏树假设下, 叶节点集合 L 上的 *additive distance matrix* $d(i, j)$ 唯一确定无根树拓扑和所有边权。

证明思路. 任取四个叶节点 a, b, c, d 。若它们在树中的 quartet 拓扑为 $ab|cd$, 即 a, b 在一侧、 c, d 在另一侧, 则四点条件给出

$$d(a, b) + d(c, d) < d(a, c) + d(b, d) = d(a, d) + d(b, c). \quad (11)$$

严格不等式的间隔等于中间分隔路径长度的两倍, 因此在正边权下可区分。

每条内部边 e 都把叶集合分成一个 bipartition $A_e|B_e$ 。对任意 $a, a' \in A_e$ 和 $b, b' \in B_e$, 式 (11) 会稳定支持 $aa'|bb'$ 。因此所有内部边诱导的 terminal split 都可由四点条件恢复。一棵最小无根树由其所有非平凡 terminal split 唯一确定, 所以拓扑唯一。

拓扑确定后, 边权可由叶间距离线性求解。例如 pendant edge 可用 limb-length 公式恢复; 内部边长度可由跨越该边的 quartet 差值恢复:

$$w_e = \frac{1}{2} [d(a, b) + d(a', b') - d(a, a') - d(b, b')], \quad (12)$$

其中 a, a' 位于 e 的一侧, b, b' 位于另一侧, 并且选择使四个叶的路径只共同穿过边 e 。因此 d 唯一确定拓扑和边权。□

定理 2 (NJ 在准确 additive distance 下的恢复性). 若输入 d 是由满足最小隐藏树假设的 T 诱导的准确 additive distance, 则 Neighbor Joining 递归生成的 latent tree 与 T 拓扑等价, 边权也可恢复。

证明思路. 首先, 准确 additive tree 中至少存在一对 cherry, 即共享同一个隐藏父节点的叶节点。NJ 的 Q 准则并不是简单选择 $d(i, j)$ 最小的 pair, 而是扣除了 S_i, S_j 代表的全局离群程度。对 additive tree, 可证明某个 true cherry 的 Q 值达到最小。因此第一步合并不会破坏真实拓扑。

设 NJ 正确合并 cherry a, b 并生成新节点 u 。由式 (7),

$$d(u, k) = \frac{1}{2} \{d(a, k) + d(b, k) - d(a, b)\}$$

恰好等于真实隐藏父节点到 k 的路径长度。因此合并后的 reduced distance matrix 仍然是收缩后真实树的 additive distance。

对叶节点数归纳: 当只剩三个 active 节点时, 拓扑唯一; 若 $m > 3$, 第一步正确合并 cherry, 且更新后仍为准确 additive distance, 于是递归成立。故 NJ 恢复原树的最小无根拓扑。□

6 距离矩阵有误差时应如何生成隐藏节点

实际中得到的是

$$\hat{d}(i, j) = d(i, j) + \varepsilon_{ij}. \quad (13)$$

误差会在两处造成破坏:

1. sibling/cherry 选择错误: 错误 pair 的 Q 值小于真实 cherry;
2. branch length 病态: 估计边长为负或接近零, 说明该 split 不稳定。

可行的鲁棒流程如下。

6.1 Bootstrap Neighbor Joining

从原始 P/Q/V 时间序列重采样, 或对估计距离矩阵加入与估计方差匹配的扰动:

$$\hat{d}^{(b)} = \hat{d} + \eta^{(b)}, \quad b = 1, \dots, B. \quad (14)$$

每次运行 NJ, 得到 latent tree $T^{(b)}$ 。由于隐藏节点标签任意, 不能直接比较 $-1, -2$ 的编号, 应比较每条内部边诱导的 terminal split。split 置信度定义为

$$\pi(S) = \frac{1}{B} \sum_{b=1}^B \mathbf{1}\{S \text{ appears in } T^{(b)}\}. \quad (15)$$

最终只保留 $\pi(S) \geq \tau$ 的高置信 hidden split。低置信区域可保留为未解析 multifurcation, 或交给局部 pseudo-root 二次辨识。

6.2 Regularized/Constrained Distance Projection

在运行 NJ 前, 可先把 $\hat{d}$ 投影到更接近 tree metric 的集合:

$$\min_{d' \in \mathcal{T}} \sum_{i < j} \omega_{ij} (d'_{ij} - \hat{d}_{ij})^2, \quad (16)$$

其中 $\mathcal{T}$ 是满足四点条件的 tree metric 集合或其近似约束。实践中可用:

- 非负边长约束;
- 去除明显违反四点条件的高噪声频段;
- 对 R, X 施加对称、非负和 shrinkage;
- 多场景联合估计, 降低 ε_{ij} 方差。

6.3 与当前项目的建议组合

对当前 terminal-load-only 配电网, 更稳的 pipeline 应为:

1. 多场景 AC 数据估计 $\hat{R}, \hat{X}$;
2. 构造 $\hat{d}_R, \hat{d}_X$, 并输出估计方差或 bootstrap 样本;
3. 对每个 bootstrap 样本运行 NJ;
4. 用 terminal split frequency 形成 hidden-edge posterior;
5. 对高置信 split 生成 hidden node;
6. 对低置信局部区域使用 pseudo-root local re-identification;
7. 最终用 split F1, 而不是 hidden node raw labels, 评价隐藏拓扑。

7 参考文献

参考文献

- [1] N. Saitou and M. Nei, The neighbor-joining method: a new method for reconstructing phylogenetic trees, *Molecular Biology and Evolution*, 4(4):406–425, 1987.
- [2] K. Atteson, The performance of neighbor-joining algorithms of phylogeny reconstruction, *COCOON 1997*, Lecture Notes in Computer Science 1276.
- [3] R. Mihaescu, D. Levy, and L. Pachter, Why neighbor-joining works, arXiv:cs/0602041, 2006. <https://arxiv.org/abs/cs/0602041>
- [4] M. J. Choi, V. Y. F. Tan, A. Anandkumar, and A. S. Willsky, Learning latent tree graphical models, arXiv:1009.2722, 2010. <https://arxiv.org/abs/1009.2722>

- [5] A. Anandkumar, K. Chaudhuri, D. Hsu, S. M. Kakade, L. Song, and T. Zhang, Spectral methods for learning multivariate latent tree structure, arXiv:1107.1283, 2011. <https://arxiv.org/abs/1107.1283>
- [6] D. Deka, S. Backhaus, and M. Chertkov, Learning topology of distribution grids using only terminal node measurements, arXiv:1608.05031, 2016. <https://arxiv.org/abs/1608.05031>
- [7] S. Park, D. Deka, and M. Chertkov, Exact topology and parameter estimation in distribution grids with minimal observability, arXiv:1710.10727, 2017. <https://arxiv.org/abs/1710.10727>
- [8] D. Deka, V. Kekatos, and G. Cavraro, Learning distribution grid topologies: a tutorial, arXiv:2206.10837, 2022. <https://arxiv.org/abs/2206.10837>