

随机误差下配电网终端量测拓扑辨识精度提升指南

面向 terminal-only 隐藏节点树、AC 潮流数据与 reduced sensitivity/MST 方法

terminal_load_only_case33 项目说明

2026 年 7 月 9 日

摘要

本文系统整理在智能电表随机量测误差、根节点电压公共模态、负荷相关性和 AC-LinDistFlow 模型失配共同存在时，如何提高配电网 terminal-only 拓扑辨识精度。对象是单根径向配电树：根节点可观测，内部节点隐藏且零注入，仅末端节点有 P/Q/V 智能表。核心观测模型为

$$V_0(t)^2 - V_i(t)^2 \approx \sum_j R_{ij} P_j(t) + \sum_j X_{ij} Q_j(t) + \gamma_{i,s} + \varepsilon_i(t),$$

再由

$$d_{ij}^R = R_{ii} + R_{jj} - 2R_{ij}, \quad d_{ij}^X = X_{ii} + X_{jj} - 2X_{ij}$$

构造 terminal-equivalent tree。本文强调：单一滤波窗口不是物理真值；面对新场景，应使用无监督的残差预测、重采样稳定性、矩阵树后验熵和物理约束一致性来自适应选择或集成。

目录

1 问题定义与误差来源	3
1.1 terminal-only 隐藏节点树	3
1.2 为什么随机误差会显著影响 MST 边	3
1.3 误差分解	4
2 基础估计器：多场景约束电压降回归	4
2.1 多场景固定效应模型	4
2.2 对称与非负约束	5
3 方法一：加权最小二乘与广义最小二乘	5
3.1 异方差噪声建模	5
3.2 GLS 处理公共模态	6
4 方法二：errors-in-variables、TLS 与去衰减	6
4.1 OLS 的衰减偏差	6
4.2 修正最小二乘	6
4.3 Total Least Squares	7

目录	2
5 方法三：工具变量与外生扰动	7
5.1 工具变量条件	7
5.2 两阶段最小二乘	7
6 方法四：滤波、频域选择与自适应窗口	8
6.1 滤波的本质	8
6.2 无先验参数选择：预测误差 + 稳定性	8
6.3 窗口集成而非单窗口	9
7 方法五：common mode 与低秩扰动消除	9
7.1 低秩公共模态模型	9
8 方法六：鲁棒回归与异常点处理	9
8.1 Huber 与 Tukey 损失	9
8.2 场景级异常诊断	10
9 方法七：bootstrap、stability selection 与概率树	10
9.1 bootstrap 方差估计	10
9.2 stability selection 的误选控制思想	10
9.3 矩阵树后验	11
9.4 温度参数自适应	11
10 方法八：tree metric 投影与 additivity 约束	11
10.1 四点条件	11
10.2 局部 quartet voting	12
11 方法九：R/X 组合距离与多视角一致性	12
12 方法十：主动激励与最优实验设计	12
12.1 为什么主动激励最有效	12
12.2 无功 probe	13
13 方法十一：Kalman/状态空间滤波与时间变化拓扑	13
14 方法十二：AC 模型误差修正	13
14.1 AC residual linearization	13
15 推荐的综合算法	14
15.1 离线无先验推荐流程	14
15.2 默认参数建议	14
15.3 精度提升路线优先级	15
16 与当前实验结果的关系	15

1 问题定义与误差来源

1.1 terminal-only 隐藏节点树

设配电网为一棵树

$$\mathcal{T} = (\mathcal{V}, \mathcal{E}), \quad r \in \mathcal{V}$$

其中 r 为馈线出口或配变低压侧根节点。节点集合分为

$$\mathcal{V} = \{r\} \cup \mathcal{H} \cup \mathcal{L},$$

$\mathcal{H}$ 为不可观内部隐藏节点, $\mathcal{L}$ 为 observed terminal leaves。严格 terminal-load-only 假设为

$$P_h(t) = Q_h(t) = 0, \quad h \in \mathcal{H}, \quad P_\ell(t), Q_\ell(t), V_\ell(t) \text{ 可测}, \quad \ell \in \mathcal{L}.$$

根节点提供 $V_0(t)$ 或 $V_r(t)$, 也可提供总功率, 但内部节点无 P/Q/V 表计。

在径向网络上, 若使用 squared-voltage LinDistFlow 的小信号形式, 则对 terminal 节点有

$$\Delta v_{\mathcal{L}}(t) \equiv V_0(t)^2 \mathbf{1} - V_{\mathcal{L}}(t)^{\circ 2} \approx R P_{\mathcal{L}}(t) + X Q_{\mathcal{L}}(t), \quad (1)$$

其中 $R, X \in \mathbb{R}^{m \times m}$, $m = |\mathcal{L}|$ 。对任意两个 terminal i, j , R_{ij} 是从根到 i, j 的公共路径电阻和; X_{ij} 同理。因此

$$d_{ij}^R = R_{ii} + R_{jj} - 2R_{ij} = \sum_{e \in \text{path}(i,j)} r_e, \quad (2)$$

这正是 terminal-terminal additive tree distance。若 d^R 估计准确, 则 minimum spanning tree 或 latent-tree 方法可恢复 terminal-equivalent topology; 若要恢复完整隐藏物理树, 还需额外的 latent tree reconstruction 或 candidate hidden graph。

1.2 为什么随机误差会显著影响 MST 边

令真实距离为 d_{ij} , 估计距离为

$$\hat{d}_{ij} = d_{ij} + \eta_{ij}.$$

MST 的边选择是非连续的排序操作: 只要两个候选边距离差

$$\Delta = d_{ab} - d_{cd}$$

与误差差值

$$\eta_{cd} - \eta_{ab}$$

同数量级, 边排序就可能翻转。若 η_{ab}, η_{cd} 近似独立正态且方差均为 σ_d^2 , 则错误排序概率近似为

$$\Pr(\hat{d}_{ab} > \hat{d}_{cd} \mid d_{ab} < d_{cd}) = \Phi\left(-\frac{\Delta}{\sqrt{2}\sigma_d}\right). \quad (3)$$

这说明提高精度的关键不只是降低平均 RMSE, 还要增大边排序 margin 或降低距离估计方差。对于 terminal-only 网络, 兄弟 terminal 的服务线长度接近、共同路径很长时, Δ 本来就小, 所以随机误差会被 MST 放大为错边。

1.3 误差分解

当前场景中，误差可分为五类：

$$\hat{P}(t) = P(t) + \epsilon_P(t), \quad (4)$$

$$\hat{Q}(t) = Q(t) + \epsilon_Q(t), \quad (5)$$

$$\hat{V}(t) = V(t) + \epsilon_V(t), \quad (6)$$

$$\hat{V}_0(t) = V_0(t) + \epsilon_0(t), \quad (7)$$

$$V_0(t)^2 - V_i(t)^2 = \sum_j R_{ij} P_j(t) + \sum_j X_{ij} Q_j(t) + b_i(P, Q, V_0) + \epsilon_i(t). \quad (8)$$

其中 $b_i(\cdot)$ 是 AC 潮流相对于线性模型的系统误差，通常随负荷水平、电压降和损耗项变化。因此“随机误差”在回归中并不只是白噪声，还会和如下因素耦合：

- P/Q 量测噪声导致 errors-in-variables bias;
- V 噪声经过平方变换后变成 $2V\epsilon_V + \epsilon_V^2$;
- 根节点电压共同波动造成 common mode;
- PV、风电和负荷日内趋势造成强共线性;
- AC 非线性损耗项造成慢变模型偏差;
- MST 对距离排序敏感。

2 基础估计器：多场景约束电压降回归

2.1 多场景固定效应模型

设共有 S 个场景，每个场景 s 有 T_s 个样本。定义

$$y_{s,t,i} = \hat{V}_{0,s}(t)^2 - \hat{V}_{i,s}(t)^2.$$

基础模型为

$$y_{s,t,i} = \sum_{j=1}^m R_{ij} \hat{P}_{s,t,j} + \sum_{j=1}^m X_{ij} \hat{Q}_{s,t,j} + \gamma_{s,i} + e_{s,t,i}. \quad (9)$$

$\gamma_{s,i}$ 是场景-节点固定效应，用来吸收不同日、不同天气、不同平均根电压下的常数偏差。与单场景相比，多场景耦合的优势是共享 R, X ，但允许不同场景有不同偏置：

$$\min_{R, X, \Gamma} \sum_{s,t,i} \left(y_{s,t,i} - \sum_j R_{ij} P_{s,t,j} - \sum_j X_{ij} Q_{s,t,j} - \gamma_{s,i} \right)^2. \quad (10)$$

若所有场景堆叠为

$$y = A\theta + e,$$

则 ridge 形式为

$$\hat{\theta}_\lambda = (A^\top W A + \lambda \Lambda)^{-1} A^\top W y. \quad (11)$$

其中 W 是噪声协方差的逆， Λ 通常不惩罚固定效应项。

2.2 对称与非负约束

真实 reduced sensitivity 满足

$$R = R^\top, \quad X = X^\top, \quad R_{ij} \geq 0, \quad X_{ij} \geq 0.$$

把 R, X 用上三角参数化：

$$R_{ij} = R_{ji} = \rho_{\min(i,j), \max(i,j)}, \quad X_{ij} = X_{ji} = \xi_{\min(i,j), \max(i,j)}.$$

令

$$\theta = (\rho, \xi, \gamma),$$

则约束回归为二次规划：

$$\min_{\theta} \frac{1}{2} \left\| W^{1/2} (A\theta - y) \right\|_2^2 + \frac{\lambda}{2} \left\| \Lambda^{1/2} \theta \right\|_2^2, \quad \rho \geq 0, \quad \xi \geq 0. \quad (12)$$

这类约束能系统性提高精度，原因是它把随机噪声导致的非物理负系数、非对称系数投影回物理可行域。在样本量有限时，约束相当于加入强先验：

$$\Theta_{\text{phys}} = \{(R, X) : R = R^\top, X = X^\top, R \geq 0, X \geq 0\}.$$

若真实参数 $\theta^* \in \Theta_{\text{phys}}$ ，则投影估计的方差通常低于无约束估计，尤其当设计矩阵病态时。

3 方法一：加权最小二乘与广义最小二乘

3.1 异方差噪声建模

智能表相对误差常近似写作

$$\epsilon_P(t) \sim (0, \sigma_P^2 P(t)^2), \quad \epsilon_Q(t) \sim (0, \sigma_Q^2 Q(t)^2), \quad \epsilon_V(t) \sim (0, \sigma_V^2 V(t)^2).$$

对 squared-voltage drop

$$y_i = V_0^2 - V_i^2,$$

一阶误差传播给出

$$\text{Var}(\epsilon_{y_i}) \approx 4V_0^2 \text{Var}(\epsilon_0) + 4V_i^2 \text{Var}(\epsilon_{V_i}) - 8V_0V_i \text{Cov}(\epsilon_0, \epsilon_{V_i}). \quad (13)$$

若 root 与 terminal 电压量测误差独立，则协方差项为零。于是不同时间、不同节点的 y 噪声方差并不相同。WLS 的自然权重为

$$w_{s,t,i} = \frac{1}{\widehat{\text{Var}}(\epsilon_{y_{s,t,i}}) + \epsilon_{\text{floor}}}.$$

3.2 GLS 处理公共模态

根节点电压误差会同时进入所有 terminal 的 y_i , 导致同一时刻不同节点残差相关:

$$\text{Cov}(e_{t,i}, e_{t,k}) \approx 4V_0^2 \text{Var}(\epsilon_0), \quad i \neq k.$$

因此每个时刻的残差协方差可写为

$$\Sigma_t = \sigma_0^2 \mathbf{1}\mathbf{1}^\top + \text{diag}(\sigma_{V_1,t}^2, \dots, \sigma_{V_m,t}^2) + \Sigma_{\text{model}}. \quad (14)$$

GLS 目标为

$$\min_{\theta} \sum_{s,t} (y_{s,t} - A_{s,t}\theta)^\top \Sigma_{s,t}^{-1} (y_{s,t} - A_{s,t}\theta). \quad (15)$$

这比普通 LS 更适合 root voltage common mode 很强的场景。

4 方法二: *errors-in-variables*、*TLS* 与去衰减

4.1 OLS 的衰减偏差

式 (9) 中的自变量 P, Q 也有噪声。令真实设计矩阵为 Z , 观测为

$$\hat{Z} = Z + U, \quad y = Z\beta + \epsilon.$$

OLS 使用 $\hat{Z}$ 回归:

$$\hat{\beta}_{\text{OLS}} = (\hat{Z}^\top \hat{Z})^{-1} \hat{Z}^\top y.$$

当样本数趋于无穷,

$$\hat{\beta}_{\text{OLS}} \rightarrow (\Sigma_Z + \Sigma_U)^{-1} \Sigma_Z \beta. \quad (16)$$

若 $\Sigma_U \succ 0$, 系数会向零收缩, 称为 attenuation bias。对拓扑辨识而言, 这会压缩距离差异, 使 MST 边 margin 变小。

4.2 修正最小二乘

若知道或可估计 Σ_U , 可用 corrected least squares:

$$\hat{\beta}_{\text{CLS}} = \left(\hat{Z}^\top \hat{Z} - n\hat{\Sigma}_U \right)^{-1} \hat{Z}^\top y. \quad (17)$$

带 ridge 与约束时可写为

$$\min_{\beta \in \Theta_{\text{phys}}} \frac{1}{2} \beta^\top \left(\hat{Z}^\top \hat{Z} - n\hat{\Sigma}_U + \lambda I \right) \beta - \beta^\top \hat{Z}^\top y. \quad (18)$$

实践中必须保证二次项半正定; 若不半正定, 可加入 λI 或投影到 PSD cone。

4.3 Total Least Squares

TLS 同时修正 Z 和 y :

$$\min_{\Delta Z, \Delta y, \beta} \|[\Delta Z, \Delta y]\|_F^2, \quad y + \Delta y = (Z + \Delta Z)\beta. \quad (19)$$

令 $C = [Z, y]$, 对 C 做 SVD:

$$C = U\Sigma V^\top.$$

若最小奇异向量分块为

$$v_{\min} = \begin{bmatrix} v_x \\ v_y \end{bmatrix}, \quad v_y \neq 0,$$

则单输出 TLS 解为

$$\hat{\beta}_{\text{TLS}} = -\frac{v_x}{v_y}. \quad (20)$$

多输出情形可对每个 terminal 方程分别做 TLS, 或使用 structured TLS。TLS 对 P/Q 噪声有效, 但标准 TLS 不自动保证 $R = X^\top$ 、非负性和 tree-metric 结构, 故更适合作为约束 QP 的初始化或偏差修正模块。

5 方法三：工具变量与外生扰动

5.1 工具变量条件

若能获得与真实 P/Q 相关、但与量测噪声和电压残差不相关的工具变量 G , 可用 IV 估计:

$$\mathbb{E}[G^\top U] = 0, \quad \mathbb{E}[G^\top \epsilon] = 0, \quad \text{rank } \mathbb{E}[G^\top Z] = p.$$

则

$$\hat{\beta}_{\text{IV}} = (G^\top \hat{Z})^{-1} G^\top y. \quad (21)$$

在配电网中, 候选工具变量包括:

- 上一时刻或低频预测负荷: $G(t) = \hat{P}(t-1)$, 适合白噪声表计误差;
- 天气驱动 PV/风电预测: 与真实 DER 出力相关, 但与电压表噪声无关;
- 可控小扰动或 probe 信号: 例如小发电机、逆变器无功阶跃;
- 聚合 feeder 总功率: 可作为总量约束和工具变量。

5.2 两阶段最小二乘

2SLS 首先把含噪自变量投影到工具变量张成空间:

$$\hat{Z}_{\text{IV}} = P_G \hat{Z}, \quad P_G = G(G^\top G)^{-1} G^\top.$$

然后回归:

$$\hat{\beta}_{2\text{SLS}} = (\hat{Z}^\top P_G \hat{Z})^{-1} \hat{Z}^\top P_G y. \quad (22)$$

若工具变量有效, 2SLS 能显著减轻 P/Q 随机误差造成的系数衰减。但若工具变量弱, 方差会变大。弱工具可用第一阶段 R^2 、F 统计量或奇异值检查。

6 方法四：滤波、频域选择与自适应窗口

6.1 滤波的本质

当前实验中，rolling high-pass 的形式为

$$\tilde{z}(t) = z(t) - \frac{1}{w} \sum_{\tau=t-\lfloor w/2 \rfloor}^{t+\lfloor w/2 \rfloor} z(\tau).$$

若一天 $T = 960$ 点，则采样间隔为 90 秒， $w = 288$ 对应 7.2 小时的趋势剥离。它不是物理线路参数，而是将日内慢趋势、根节点共同模态、AC 慢变模型误差从局部激励中分离出来。

频域滤波可写为

$$z(t) = \sum_{k=0}^{T-1} \hat{z}_k e^{i2\pi kt/T}.$$

保留频带 $\mathcal{K}$:

$$\tilde{z}(t) = \sum_{k \in \mathcal{K}} \hat{z}_k e^{i2\pi kt/T}. \quad (23)$$

低频包含日照和负荷包络，高频包含表计噪声；有用拓扑激励通常在中间频带。

6.2 无先验参数选择：预测误差 + 稳定性

面对新场景，不能用真实边恢复率选窗口。设候选滤波器集合为

$$\mathcal{F} = \{F_1, \dots, F_K\}.$$

对每个 F_k ，做 B 次场景或日期 bootstrap。第 b 次得到 $\hat{R}^{(k,b)}$ 和 MST $\hat{T}^{(k,b)}$ 。定义边频率

$$\pi_e^{(k)} = \frac{1}{B} \sum_{b=1}^B \mathbf{1}\{e \in \hat{T}^{(k,b)}\}. \quad (24)$$

边熵为

$$H^{(k)} = -\frac{1}{|\mathcal{E}_c|} \sum_{e \in \mathcal{E}_c} \left[\pi_e^{(k)} \log(\pi_e^{(k)} + \delta) + (1 - \pi_e^{(k)}) \log(1 - \pi_e^{(k)} + \delta) \right]. \quad (25)$$

同时做 held-out 场景预测：

$$\text{RMSE}_{\text{val}}^{(k)} = \sqrt{\frac{1}{N_{\text{val}}} \sum_{(s,t,i) \in \mathcal{D}_{\text{val}}} \left(y_{s,t,i} - \hat{y}_{s,t,i}^{(k)} \right)^2}. \quad (26)$$

推荐选择准则：

$$\text{score}(F_k) = \text{RMSE}_{\text{val}}^{(k)} + \lambda_H H^{(k)} + \lambda_C \log \kappa(A_k) + \lambda_{RX} D_{RX}^{(k)}. \quad (27)$$

其中 D_{RX} 衡量 d^R 与 d^X 给出的树是否一致。选

$$F^* = \arg \min_{F_k \in \mathcal{F}} \text{score}(F_k).$$

这比固定 $w = 288$ 更适合新场景。

6.3 窗口集成而非单窗口

更稳健的方式是窗口集成。令每个滤波器输出边频率 $\pi_e^{(k)}$, 加权为

$$s_e = \sum_{k=1}^K \omega_k \pi_e^{(k)}, \quad \omega_k \propto \exp[-\alpha \text{score}(F_k)]. \quad (28)$$

最终取最大生成树:

$$\hat{T}_{\text{ens}} = \arg \max_{T \in \mathfrak{T}} \sum_{e \in T} s_e. \quad (29)$$

这样可以避免单个窗口对某个场景过拟合。

7 方法五: common mode 与低秩扰动消除

7.1 低秩公共模态模型

根电压波动、日照共同包络和系统级负荷同步变化通常表现为低秩结构:

$$Y = ZB + LC^\top + E,$$

其中 $Y \in \mathbb{R}^{n \times m}$ 是电压降矩阵, $Z = [P, Q]$, $B = [R^\top, X^\top]^\top$, $LC^\top$ 是 rank- q 的公共模态项。优化问题为

$$\min_{B, L, C} \|Y - ZB - LC^\top\|_F^2 + \lambda_B \mathcal{R}(B), \quad \text{rank}(LC^\top) \leq q. \quad (30)$$

也可用 nuclear norm 松弛:

$$\min_{B, M} \frac{1}{2} \|Y - ZB - M\|_F^2 + \lambda_M \|M\|_* + \lambda_B \mathcal{R}(B). \quad (31)$$

实践中常用更简单的步骤: 先对 Y, P, Q 做每日去均值、高通或 PCA 去除前几个主成分, 再回归。但必须避免去掉与拓扑有关的局部信号。

8 方法六: 鲁棒回归与异常点处理

8.1 Huber 与 Tukey 损失

电表通信异常、PV 突变、AC 潮流未完全收敛或错误挂表会造成重尾残差。普通二乘损失

$$\rho(u) = \frac{1}{2}u^2$$

对离群点敏感。Huber 损失为

$$\rho_\delta(u) = \begin{cases} \frac{1}{2}u^2, & |u| \leq \delta, \\ \delta(|u| - \frac{1}{2}\delta), & |u| > \delta. \end{cases} \quad (32)$$

对应 M-estimator:

$$\min_{\theta \in \Theta_{\text{phys}}} \sum_{s, t, i} \rho_\delta \left(\frac{y_{s, t, i} - a_{s, t, i}^\top \theta}{\hat{\sigma}_i} \right). \quad (33)$$

其迭代加权形式为

$$w_r = \frac{\psi(r)}{r}, \quad \psi(r) = \rho'(r),$$

然后解加权约束 LS。优点是自动降低异常样本权重；缺点是若大比例系统误差被误判为异常，可能丢掉有效激励。

8.2 场景级异常诊断

对每个场景 s 计算

$$\text{RMSE}_s = \sqrt{\frac{1}{T_s m} \sum_{t,i} e_{s,t,i}^2}, \quad \text{leverage}_{s,t} = a_{s,t}^\top (A^\top A)^{-1} a_{s,t}.$$

高残差且高 leverage 的样本会强烈影响 R/X 。可用 Cook 距离类指标：

$$D_{s,t} \approx \frac{e_{s,t}^2}{p\hat{\sigma}^2} \frac{h_{s,t}}{(1 - h_{s,t})^2}. \quad (34)$$

对高 D 样本可降权、剔除或单独建模。

9 方法七: bootstrap、stability selection 与概率树

9.1 bootstrap 方差估计

设估计流程为

$$\mathcal{A}: \{(P, Q, V, V_0)_s\}_{s=1}^S \mapsto \hat{T}.$$

重采样日期、场景或时间块得到 $\hat{T}^{(b)}$ 。边频率 π_e 如式 (24)。若某边 $\pi_e \approx 1$ ，说明对随机误差稳定；若 $\pi_e \approx 0.5$ ，说明处于排序边界。

terminal tree 必须有 $m - 1$ 条边，因此不能简单选 $\pi_e > \tau$ ；应把 π_e 当权重做 maximum spanning tree：

$$\hat{T}_{\text{stab}} = \arg \max_{T \in \mathfrak{T}} \sum_{e \in T} \pi_e.$$

9.2 stability selection 的误选控制思想

Stability selection 的核心是：对随机子样本反复运行基础选择器，保留高选择概率变量。对边选择而言，变量就是候选边 e 。设阈值 π_{thr} ，选择

$$\hat{E}_{\text{stable}} = \{e : \pi_e \geq \pi_{\text{thr}}\}.$$

原始 stability selection 给出了期望误选数量上界，其具体形式依赖交换性和选择规模假设。对于 MST，更实用的是把它改成“边置信度 + 生成树约束”的形式，即式 (9.1)。

9.3 矩阵树后验

给每条候选边一个权重

$$w_e = \exp(-\beta \hat{d}_e),$$

定义所有生成树上的 Gibbs 分布:

$$\Pr(T \mid \hat{d}) = \frac{1}{Z} \prod_{e \in T} w_e, \quad Z = \sum_{T \in \mathfrak{T}} \prod_{e \in T} w_e. \quad (35)$$

由矩阵树定理, 若 $L(w)$ 是加权图 Laplacian, 删除根行列得 $L_{\bar{r}}$, 则

$$Z = \det L_{\bar{r}}.$$

边 $e = (u, v)$ 的边际概率为

$$p_e = w_e b_e^\top L_{\bar{r}}^{-1} b_e, \quad (36)$$

其中 b_e 是边关联向量删除根节点后的版本。若 p_e 集中在 $m - 1$ 条边附近, 拓扑置信度高; 若大量边 p_e 接近, 则随机误差导致不可区分。

9.4 温度参数自适应

β 控制后验尖锐程度。可用 bootstrap 距离方差设定:

$$\beta_e = \frac{1}{\hat{\sigma}_{d,e} + \epsilon}.$$

或统一选择 β 使

$$\sum_e p_e = m - 1$$

天然成立, 同时使 posterior entropy

$$H_{\text{tree}} = - \sum_e [p_e \log p_e + (1 - p_e) \log(1 - p_e)]$$

不过大。最终可报告 MAP tree、edge marginal 和 entropy, 而不只报告一棵硬树。

10 方法八: tree metric 投影与 additivity 约束

10.1 四点条件

真实 terminal additive tree metric 满足四点条件: 任意四个叶子 a, b, c, d ,

$$d_{ab} + d_{cd}, \quad d_{ac} + d_{bd}, \quad d_{ad} + d_{bc}$$

中最大两个相等。随机误差会破坏该条件。可把估计距离 $\hat{d}$ 投影到 tree metric 集合:

$$\min_{d \in \mathcal{M}_{\text{tree}}} \sum_{i < j} \omega_{ij} (d_{ij} - \hat{d}_{ij})^2. \quad (37)$$

其中 $\mathcal{M}_{\text{tree}}$ 是所有 additive tree metrics。这个集合是多拓扑的并集, 直接求解较难; 实用方法包括 neighbor joining、recursive grouping、quartet voting 或先 MST 后局部修正。

10.2 局部 quartet voting

对每个四元组 (a, b, c, d) ，根据三种 split 的得分

$$S_{ab|cd} = d_{ab} + d_{cd}, \quad S_{ac|bd} = d_{ac} + d_{bd}, \quad S_{ad|bc} = d_{ad} + d_{bc}$$

判断哪两个较大且接近。若

$$S_{ac|bd} \approx S_{ad|bc} > S_{ab|cd},$$

则支持 split $ab|cd$ 。把所有 quartet vote 聚合成边置信度，可修正 MST 在小 margin 处的个别错边。

11 方法九：R/X 组合距离与多视角一致性

若线路 R 与 X 同数量级，则 d^X 同样是 additive tree distance。可构造

$$d_{ij}^{RX} = \alpha \frac{d_{ij}^R}{\text{median}(d^R)} + (1 - \alpha) \frac{d_{ij}^X}{\text{median}(d^X)}. \quad (38)$$

固定 α 有风险，因为某些算例中 X 噪声更大。推荐把 d^R 和 d^{RX} 视为两个 view：

$$T_R = \text{MST}(d^R), \quad T_{RX} = \text{MST}(d^{RX}).$$

定义一致性

$$J(T_R, T_{RX}) = \frac{|T_R \cap T_{RX}|}{|T_R \cup T_{RX}|}.$$

若 J 高，说明拓扑稳定；若 J 低，应进入局部诊断：检查错边附近的距离 margin、bootstrap 频率和残差影响。当前实验中，固定 d^R 在多数 case 上更稳，而 d^{RX} 能修正某些 balanced case 的局部错边。因此建议：

$$s_e = \pi_e^R + \eta \pi_e^{RX} - \mu \mathbf{1}\{e \text{ only appears in unstable view}\}. \quad (39)$$

12 方法十：主动激励与最优实验设计

12.1 为什么主动激励最有效

被动智能表数据常有强相关负荷：

$$\text{cond}(A) \gg 1.$$

估计协方差近似为

$$\text{Cov}(\hat{\theta}) \approx \sigma^2 (A^\top A)^{-1}.$$

要系统降低方差，就要增大 $A^\top A$ 的最小特征值，而不是只增加相似样本。

若可控 DER 允许注入小扰动 $u(t)$ ，设计目标可写为 D-optimal：

$$\max_{u(1:T)} \log \det(A(u)^\top A(u) + \lambda I) \quad \text{s.t.} \quad |u_j(t)| \leq \bar{u}_j, \quad V_{\min} \leq V(t) \leq V_{\max}.$$

或 E-optimal：

$$\max_{u(1:T)} \lambda_{\min}(A(u)^\top A(u)).$$

主动激励可显著提高 identifiability，尤其是区分兄弟 terminal 或近似等长 service drops。

12.2 无功 probe

逆变器无功扰动对电压敏感, 且不直接改变用户有功负荷。若第 j 个 terminal 注入

$$\Delta Q_j(t) = q_0 s_j(t),$$

其中 $s_j(t)$ 是互相正交的伪随机序列, 则

$$\Delta y_i(t) \approx X_{ij} q_0 s_j(t).$$

用相关解调:

$$\hat{X}_{ij} = \frac{1}{q_0 T} \sum_t \Delta y_i(t) s_j(t).$$

这类似 lock-in measurement, 可把随机噪声平均掉。工程上需满足电压约束、逆变器容量和用户影响约束。

13 方法十一: Kalman/状态空间滤波与时间变化拓扑

若 R, X 或电压偏差慢变, 可建状态空间模型:

$$\theta_{t+1} = \theta_t + w_t, \quad w_t \sim \mathcal{N}(0, Q_\theta), \quad (40)$$

$$y_t = A_t \theta_t + v_t, \quad v_t \sim \mathcal{N}(0, R_t). \quad (41)$$

Kalman filter 预测与更新:

$$\theta_{t|t-1} = \theta_{t-1|t-1}, \quad (42)$$

$$P_{t|t-1} = P_{t-1|t-1} + Q_\theta, \quad (43)$$

$$K_t = P_{t|t-1} A_t^\top (A_t P_{t|t-1} A_t^\top + R_t)^{-1}, \quad (44)$$

$$\theta_{t|t} = \theta_{t|t-1} + K_t (y_t - A_t \theta_{t|t-1}), \quad (45)$$

$$P_{t|t} = (I - K_t A_t) P_{t|t-1}. \quad (46)$$

这适合在线辨识。对固定拓扑离线问题, Kalman smoother 相当于带时间平滑先验的递推 GLS。

14 方法十二: AC 模型误差修正

14.1 AC residual linearization

当前数据由 AC 潮流生成, 而估计使用 reduced linear sensitivity, 系统误差不可避免。设 AC 方程为

$$F(x, u, \theta_{\text{net}}) = 0,$$

x 是电压相量, $u = (P, Q)$ 。在工作点 (x^*, u^*) 附近:

$$\Delta x \approx -F_x^{-1} F_u \Delta u.$$

这给出局部 sensitivity

$$S_{AC}(u^*) = \frac{\partial y}{\partial u} = -H_x F_x^{-1} F_u.$$

与 constant R/X 不同, S_{AC} 随工作点变化。可采用分段线性模型:

$$y_{s,t} = A_{s,t}\theta + B\phi(u_{s,t}) + e_{s,t}, \quad (47)$$

其中 $\phi(u)$ 包括总负荷、总无功、损耗近似项:

$$\phi(u) = \left[\sum_j P_j, \sum_j Q_j, \left(\sum_j P_j \right)^2, \left(\sum_j Q_j \right)^2, \sum_j P_j Q_j \right].$$

这可吸收 AC 慢变偏差, 降低对滤波窗口的依赖。但 ϕ 过多会与 R/X 共线, 需要 ridge 或 cross-validation。

15 推荐的综合算法

15.1 离线无先验推荐流程

Algorithm 1 Adaptive Stable Constrained Topology Identification

Require: 多场景 terminal P/Q/V、root voltage V_0 ; 候选窗口 $\mathcal{W}$; bootstrap 次数 B

- 1: 构造电压降 $Y_s = V_{0,s}^2 \mathbf{1}^\top - V_s^2$
 - 2: **for** $w \in \mathcal{W}$ **do**
 - 3: 对 Y_s, P_s, Q_s 应用 rolling high-pass 或频域 band-pass
 - 4: **for** $b = 1, \dots, B$ **do**
 - 5: bootstrap 抽取场景/日期/时间块
 - 6: 解对称非负约束回归 (12)
 - 7: 构造 d^R 与可选 d^{RX}
 - 8: 生成 MST, 记录边出现
 - 9: **end for**
 - 10: 计算 validation RMSE、边熵、条件数、 R/X 一致性
 - 11: **end for**
 - 12: 由式 (28) 得到跨窗口边分数 s_e
 - 13: 输出 $\hat{T} = \arg \max_T \sum_{e \in T} s_e$
 - 14: 同时输出 edge frequency、matrix-tree marginal、局部低置信边列表
-

15.2 默认参数建议

若一天 $T = 960$ 点, 建议窗口集合为

$$\mathcal{W} = \{192, 224, 240, 256, 288, 320, 360\}.$$

对应约 4.8–9 小时的慢趋势剥离。若采样点数不同, 按时间尺度而不是点数换算:

$$w(\tau) = \left\lfloor \frac{\tau}{\Delta t} \right\rfloor, \quad \tau \in \{4.8, 5.6, 6.0, 6.4, 7.2, 8.0, 9.0\} \text{ hours}.$$

默认主距离使用 d^R ；若 d^R 与 d^{RX} 在 bootstrap 中一致，合并；若不一致，优先保留 d^R ，把 d^{RX} 作为局部诊断。

15.3 精度提升路线优先级

方法	主要解决的问题	推荐程度
多场景耦合 + 固定效应	单日激励不足、根电压均值差异	必做
对称非负约束	随机噪声导致非物理系数	必做
自适应高通/频域滤波	慢变公共模态、AC 系统偏差	必做，但不可 oracle 选参
bootstrap 稳定性	MST 排序敏感、边置信度未知	必做
WLS/GLS	异方差 V/P/Q 噪声、root common mode	强烈推荐
R/X 多视角一致性	R 或 X 单一视角局部错边	推荐作辅助
EIV/TLS/IV	P/Q 自变量量测噪声偏差	有噪声标定时强烈推荐
鲁棒 M-estimator	离群点、错挂表、通信异常	推荐
tree metric/quartet 投影	距离矩阵不满足 additive tree	推荐作后处理
主动 DER probe	边 margin 太小、被动数据不可辨识	条件允许时最有效
AC residual correction	高负荷下线性模型失配	高电压降场景推荐

16 与当前实验结果的关系

在当前 case-bank 实验中，固定组合

$$\text{rolling_highpass_w288} + d^R$$

在四个论文风格算例上恢复 55/56 条 terminal-equivalent MST 边，平均 F1 约 0.983。不滤波 raw drop + d^R 为 51/56，平均 F1 约 0.915。这说明高通滤波主要提高困难边排序的稳定性。

但是 $w = 288$ 不是普适真理。它对应当前 $T = 960$ 、一天数据、90 秒采样下的 7.2 小时趋势剥离。面对新场景，应改用式 (27) 或式 (28) 的无监督选择/集成。

17 结论

随机误差下提升拓扑辨识精度不能只依赖某个滤波窗口。系统性方案应同时处理四件事：

1. 用多场景耦合和固定效应增加有效激励并隔离场景偏置；
2. 用对称、非负、tree-metric、R/X 一致性等物理约束降低估计方差；

3. 用 WLS/GLS、EIV/TLS/IV、鲁棒 M-estimator 正确建模量测误差；
4. 用 bootstrap、矩阵树后验和跨窗口集成把 MST 的硬决策变成可校准的边置信度。

如果工程上允许主动 DER probe，则最根本的提升来自最优实验设计：让 $A^T A$ 条件更好，而不是被动等待随机负荷提供足够激励。

参考文献

- [1] M. E. Baran and F. F. Wu, “Network reconfiguration in distribution systems for loss reduction and load balancing,” *IEEE Transactions on Power Delivery*, vol. 4, no. 2, pp. 1401–1407, 1989.
- [2] S. Bolognani and S. Zampieri, “On the existence and linear approximation of the power flow solution in power distribution networks,” *IEEE Transactions on Power Systems*, vol. 31, no. 1, pp. 163–172, 2016. Preprint: <https://arxiv.org/abs/1403.5031>.
- [3] L. Gan and S. H. Low, “Convex relaxations and linear approximation for optimal power flow in multiphase radial networks,” preprint, 2014. <https://arxiv.org/abs/1406.3054>.
- [4] D. Deka, S. Backhaus, and M. Chertkov, “Learning topology of distribution grids using only terminal node measurements,” preprint, 2016. <https://arxiv.org/abs/1608.05031>.
- [5] D. Deka, S. Backhaus, and M. Chertkov, “Estimating distribution grid topologies: A graphical learning based approach,” preprint, 2016. <https://arxiv.org/abs/1602.08509>.
- [6] D. Deka, S. Backhaus, and M. Chertkov, “Learning topology of the power distribution grid with and without missing data,” preprint, 2016. <https://arxiv.org/abs/1603.01650>.
- [7] J. P. Satya, N. Bhatt, R. Pasumathy, and A. Rajeswaran, “Identifying topology of power distribution networks based on smart meter data,” preprint, 2016. <https://arxiv.org/abs/1609.02678>.
- [8] Y. Guo, Y. Yuan, and Z. Wang, “Distribution grid modeling using smart meter data,” preprint, 2021. <https://arxiv.org/abs/2103.00660>.
- [9] G. H. Golub and C. F. Van Loan, “An analysis of the total least squares problem,” *SIAM Journal on Numerical Analysis*, vol. 17, no. 6, pp. 883–893, 1980.
- [10] S. Van Huffel and J. Vandewalle, *The Total Least Squares Problem: Computational Aspects and Analysis*. SIAM, 1991.
- [11] W. A. Fuller, *Measurement Error Models*. Wiley, 1987.
- [12] R. J. Carroll, D. Ruppert, L. A. Stefanski, and C. M. Crainiceanu, *Measurement Error in Nonlinear Models: A Modern Perspective*. CRC Press, 2006.

- [13] P. J. Huber and E. M. Ronchetti, *Robust Statistics*, 2nd ed. Wiley, 2009.
- [14] F. R. Hampel, E. M. Ronchetti, P. J. Rousseeuw, and W. A. Stahel, *Robust Statistics: The Approach Based on Influence Functions*. Wiley, 1986.
- [15] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. Chapman & Hall/CRC, 1993.
- [16] N. Meinshausen and P. Bühlmann, “Stability selection,” *Journal of the Royal Statistical Society: Series B*, vol. 72, no. 4, pp. 417–473, 2010.
- [17] R. D. Shah and R. J. Samworth, “Variable selection with error control: Another look at stability selection,” *Journal of the Royal Statistical Society: Series B*, vol. 75, no. 1, pp. 55–80, 2013.
- [18] R. E. Kalman, “A new approach to linear filtering and prediction problems,” *Transactions of the ASME—Journal of Basic Engineering*, vol. 82, no. 1, pp. 35–45, 1960.
- [19] G. Kirchhoff, “Ueber die Auflösung der Gleichungen, auf welche man bei der Untersuchung der linearen Vertheilung galvanischer Ströme geführt wird,” *Annalen der Physik und Chemie*, vol. 72, pp. 497–508, 1847.